



Modelli linguistici di grandi dimensioni con conoscenza aumentata per suggerimenti di query contestuali personalizzati

Jinheon Baek*
KAIST
Seoul, Corea del Sud
jinheon.baek@kaist.ac.kr

Nirupama Chandrasekaran
Microsoft Research
Redmond, WA, USA
niruc@microsoft.com

Silviu Cucerzan
Microsoft Research
Redmond, WA, USA
silviu@microsoft.com

Allen Herring
Microsoft Research
Redmond, WA, USA
allenh@microsoft.com

Sujay Kumar Jauhar
Microsoft Research
Redmond, WA, USA
sjauhar@microsoft.com

ABSTRACT

I modelli linguistici di grandi dimensioni (LLM) eccellono nell'affrontare varie attività di linguaggio naturale. Tuttavia, a causa dei costi significativi legati al loro riaddestramento o alla loro messa a punto, rimangono in gran parte statici e difficili da personalizzare. Ciononostante, una varietà di applicazioni potrebbe trarre vantaggio da generazioni personalizzate in base alle preferenze, agli obiettivi e alle conoscenze degli utenti. Tra queste vi è la ricerca sul web, dove conoscere ciò che un utente sta cercando di realizzare, ciò che gli interessa e ciò che sa può portare a esperienze di ricerca migliorate. In questo lavoro, proponiamo un approccio nuovo e generale che arricchisce un LLM con il contesto rilevante tratto dalla cronologia delle interazioni degli utenti con un motore di ricerca, al fine di personalizzarne i risultati. Nello specifico, costruiamo un archivio di conoscenze incentrato sulle entità per ciascun utente sulla base delle sue attività di ricerca e navigazione sul web, che viene poi utilizzato per fornire integrazioni contestualmente rilevanti ai prompt LLM. Questo archivio di conoscenze è leggero, poiché produce solo proiezioni aggregate specifiche dell'utente relative agli interessi e alle conoscenze su grafici di conoscenza pubblici e sfrutta l'infrastruttura esistente dei log di ricerca, mitigando così le preoccupazioni relative alla privacy, alla conformità e alla scalabilità associate alla creazione di profili utente approfonditi per la personalizzazione. Convalidiamo il nostro approccio sul compito di suggerimento di query contestuali, che richiede la comprensione non solo del contesto di ricerca attuale dell'utente, ma anche di ciò che conosce e gli interessa storicamente. Attraverso una serie di esperimenti basati sulla valutazione umana, dimostriamo che il nostro approccio è significativamente migliore rispetto a diverse altre linee di base basate su LLM, generando suggerimenti di query contestualmente più rilevanti, personalizzati e utili.

CONCETTI CCS

- Metodologie di calcolo → Elaborazione del linguaggio naturale;
- Sistemi informativi → Personalizzazione.

*Questo lavoro è stato svolto durante uno stage presso Microsoft Research.



Questo lavoro è concesso in licenza ai sensi della licenza Creative Commons Attribution International 4.0.

WWW '24, 13-17 maggio 2024, Singapore, Singapore

© 2024 Copyright detenuto dal proprietario/dagli autori. ACM
ISBN 979-8-4007-0171-9/24/05

<https://doi.org/10.1145/3589334.3645404>




Figura 1: Illustrazione del nostro framework K-LaMP (Knowledge-augmented large Language Model for Personalization) per suggerimenti contestuali. (A) Il contesto di ricerca di un utente include una query corrente e una pagina visualizzata. (B) L'utente ha conoscenze di medicina, estratte dalle attività di ricerca passate. (C) I suggerimenti di query convenzionali con LLM ingenui generano una query non correlata alle conoscenze dell'utente e al contesto. (D) K-LaMP suggerisce una query personalmente e contestualmente rilevante.

PAROLE CHIAVE

Modelli linguistici di grandi dimensioni, personalizzazione, conoscenza incentrata sulle entità, suggerimento contestuale delle query

Formato di riferimento ACM:

Jinheon Baek, Nirupama Chandrasekaran, Silviu Cucerzan, Allen Herring e Sujay Kumar Jauhar. 2024. Modelli linguistici di grandi dimensioni con conoscenza aumentata per suggerimenti di query contestuali personalizzati. In *Atti della ACM Web Conference 2024 (WWW '24)*, 13-17 maggio 2024, Singapore, Singapore. ACM, New York, NY, USA, 12 pagine. <https://doi.org/10.1145/3589334.3645404>

1 INTRODUZIONE

I modelli linguistici di grandi dimensioni (LLM) [6, 9, 16, 53, 69, 70], come GPT-4, sono modelli con miliardi di parametri addestrati su enormi corpora di testo, in grado di interiorizzare conoscenze generali in diversi ambiti [55, 59]. Questa capacità consente loro di generare output plausibili, ragionevoli e utili in risposta agli input degli utenti, che sono stati sfruttati con risultati impressionanti per una vasta gamma di compiti in linguaggio naturale, tra cui la risposta a domande e la generazione di dialoghi, anche senza alcun addestramento specifico per il compito [6, 53, 70].

Nonostante questi successi, personalizzare gli LLM per generare risposte personalizzate, che tengano conto delle preferenze individuali, delle esigenze, delle conoscenze e del contesto degli utenti, con l'obiettivo di renderle più significative e pertinenti per ciascun utente, rimane una sfida. Ciò è dovuto al fatto che il riaddestramento o la messa a punto degli LLM per i singoli utenti è proibitivo dal punto di vista economico. Nel frattempo, per alcune applicazioni del mondo reale, come i suggerimenti di query [22, 65], i consigli sugli articoli [26, 77], la generazione di snippet [13] o la risposta alle domande [31], è essenziale riflettere le preferenze personali, le conoscenze e le esigenze degli utenti nei risultati del modello.

Diversi studi recenti [20, 29, 32, 36, 46, 48] hanno affrontato il problema della personalizzazione dei modelli LLM attraverso l'integrazione degli input degli utenti con informazioni rilevanti, un processo noto come apprendimento contestuale [9, 39, 58, 75]. Ad esempio, al fine di suggerire il prossimo elemento con cui l'utente potrebbe interagire, essi antepongono una sequenza delle loro interazioni passate con gli elementi all'input dell'LLM [14, 46]. A causa del volume spesso elevato delle informazioni storiche degli utenti, lavori più recenti [60, 64, 73, 79] propongono di inserire solo una parte della cronologia più rilevante, recuperandola da una memoria di interazione completa. Tale personalizzazione basata sul recupero, pur dimostrando il proprio successo in diversi compiti, tra cui la raccomandazione di prodotti e l'assistenza alla scrittura [14, 44, 60, 73], rimane inadatta a scenari di personalizzazione più impegnativi in cui è fondamentale una comprensione più approfondita delle conoscenze personali degli utenti. Nel frattempo, alcuni studi [38, 80] consentono la personalizzazione attraverso la costruzione di profili utente approfonditi che vengono poi incorporati nei prompt LLM. Tuttavia, tale personalizzazione basata sui profili cattura le conoscenze degli utenti a scapito della privacy e della scalabilità, richiedendo una modellazione online che va oltre le capacità dell'infrastruttura di registrazione esistente.

Pertanto, in questo articolo, introduciamo un nuovo approccio alla personalizzazione dell'output degli LLM. Il nostro metodo ruota attorno a un livello di personalizzazione leggero e incentrato sulle entità che consente l'aumento delle conoscenze degli LLM con entità contestuali recuperate da un archivio di conoscenze personali. Questo archivio di conoscenze deriva dai log di ricerca esistenti che catturano le interazioni degli utenti con i moderni motori di ricerca. Nello specifico, questo archivio viene costruito nel tempo aggregando le entità apparse nelle query emesse dall'utente o nelle pagine web che ha consultato, ed è ulteriormente arricchito da diverse visualizzazioni che catturano le entità che l'utente potrebbe conoscere o non conoscere e quelle che potrebbero essere recentemente svanite dalla sua memoria.

Questa strategia di personalizzazione incentrata sulle entità presenta diversi vantaggi. In primo luogo, i recuperi contestualmente rilevanti da questo archivio di conoscenze incentrato sulle entità incoraggiano gli LLM a generare output più profondamente radicati in ciò che gli utenti conoscono e a cui tengono rispetto ai registri delle query passate archiviati in modo lineare. Allo stesso tempo, si basa in gran parte su un'infrastruttura di registrazione già esistente, il che significa che è più suscettibile a considerazioni di privacy, flessibilità e scalabilità rispetto alla personalizzazione basata sul profilo, poiché riduce i costi di raccolta, modellizzazione e aggiornamento dei dati. Inoltre, grazie al suo design leggero, il nostro approccio offre una facile integrazione con gli LLM esistenti per altre attività di personalizzazione, sia nella ricerca [13, 31] che oltre [44, 60]. Infine, il nostro metodo di aumento della conoscenza è efficiente in termini di costi, poiché l'iniezione di conoscenza utilizza entità come atomi. Ciò si traduce in aggiunte minime e concise al prompt, a differenza di altri approcci di contestualizzazione LLM che operano su testo grezzo [39, 58, 75]. Ci riferiamo al nostro framework come Knowledge-augmented large Language Models for Personalization, o K-LaMP.

Sebbene il nostro metodo di personalizzazione degli output LLM sia ampiamente applicabile ai problemi nella ricerca (e oltre), è particolarmente rilevante per le attività che richiedono la modellizzazione delle conoscenze degli utenti oltre ai loro interessi. Una di queste attività impegnative è una nuova variante del suggerimento di query [4, 12, 23, 66], che chiamiamo suggerimento di query contestuale. In questa variante, un sistema deve raccomandare all'utente delle query in base alla pagina web che sta leggendo, oltre che alle sue informazioni storiche di query. Pertanto, in questo contesto, conoscere il dominio di competenza e la padronanza di un utente su un particolare argomento può portare a suggerimenti sostanzialmente diversi, come mostrato nella Figura 1. Vale la pena notare che il suggerimento contestuale delle query è diverso dall'attuale suggerimento contestuale delle query presente in letteratura [5, 15, 34, 37], poiché quest'ultimo non condiziona i suggerimenti al contenuto della pagina web visualizzata dall'utente, né cattura esplicitamente le conoscenze dell'utente, concentrandosi invece sulle relazioni superficiali tra le query e le pagine o i loro titoli.

Nel nostro studio, convalidiamo l'efficacia di K-LaMP per il suggerimento contestuale delle query, utilizzando i log di ricerca reali del motore di ricerca Bing [2], che viene utilizzato anche per costruire il nostro archivio di conoscenze incentrato sulle entità. Da una serie di test condotti tramite valutazione umana, abbiamo riscontrato che K-LaMP supera sostanzialmente diversi modelli di riferimento di suggerimento di query (contestuali) basati su LLM nella generazione di raccomandazioni più pertinenti e utili per gli individui, mantenendo al contempo un'elevata qualità dei risultati di ricerca. Ulteriori analisi dimostrano che K-LaMP recupera le conoscenze contestualmente rilevanti in modo altamente efficace e continua a migliorare le proprie prestazioni man mano che vengono elaborate e archiviate cronologie di interazione degli utenti più lunghe, cosa che nessun altro sistema di riferimento è in grado di fare.

2 CONTESTO E LAVORI CORRELATI

Modelli linguistici di grandi dimensioni. I modelli linguistici [24, 47, 56, 57], che sono pre-addestrati su corpora di testi non annotati utilizzando architetture Transformer [71] basate su obiettivi di apprendimento auto-supervisionati, hanno dimostrato di acquisire conoscenze dai corpora di testi [55, 59, 67] e sono stati utilizzati con successo per varie attività di linguaggio naturale, come la risposta a domande e la generazione di dialoghi [35, 68]. Recentemente, i modelli linguistici di grandi dimensioni (LLM) [6, 53, 70], che sono versioni potenziate dei modelli linguistici, hanno dimostrato la capacità di gestire diverse attività linguistiche in vari ambiti. In particolare, gli LLM hanno mostrato una maggiore capacità di acquisizione e conservazione delle conoscenze grazie al loro numero molto elevato di parametri [49, 78], nonché una notevole capacità di generalizzare in nuovi domini senza necessità di ulteriori aggiustamenti specifici per le attività e dati di addestramento [62, 74]. Inoltre, sono in grado di comprendere il contesto di determinati input e quindi di generare risposte coerenti dal punto di vista contestuale, consentendo agli utenti e ai progettisti di sistemi di personalizzare facilmente le risposte degli LLM attraverso il prompt engineering [39, 58, 75]. Ad esempio, per generare risposte fattualmente corrette in risposta alle domande immesse, i lavori esistenti [7, 40, 63] tipicamente aumentano la conoscenza internalizzata nei LLM con conoscenze fattuali esterne rilevanti relative alle domande. Tuttavia, sebbene siano in grado di fornire efficacemente risposte generiche che possono essere applicate a un'ampia gamma di utenti, rimane difficile generare risposte personalizzate che catturino le preferenze, le esigenze e le conoscenze uniche dei singoli utenti.

Modelli linguistici di grandi dimensioni per la personalizzazione. Al fine di produrre output personalizzati per i singoli utenti, studi recenti [10,

45] propongono di personalizzare le generazioni di LLM, con applicazioni che abbracciano vari compiti e domini. Questi includono raccomandazioni di prodotti o contenuti [14, 27, 30, 73], generazione di dialoghi

[64, 79], assistenti di scrittura [44, 60] e persino sistemi robotici [76]. Nello specifico, i primi lavori [20, 29, 32, 36, 46, 48] propongono di incorporare la sequenza storica delle interazioni dell'utente (ad esempio, i registri degli acquisti recenti di articoli) nei prompt degli LLM, consentendo così agli LLM di generare output personalizzati (ad esempio, la raccomandazione dell'articolo successivo). Sebbene questo meccanismo di iniezione semplice e lineare possa fornire efficacemente agli LLM informazioni contestuali rilevanti per la personalizzazione, esso è limitato da cronologie di interazione spesso molto estese che superano la capacità delle finestre di prompt degli LLM. Inoltre, non tutta questa cronologia è rilevante per ogni query. Sulla base di questa osservazione, lavori recenti [60, 64, 73, 79] recuperano invece i contenuti rilevanti da una memoria esterna [54] che memorizza le informazioni storiche dell'utente. Alcuni studi [44, 79] fanno un passo avanti, elaborando le informazioni nella memoria delle interazioni – ad esempio, con la sintesi o l'estrazione di parole chiave – per ottenere informazioni di livello superiore dalla cronologia dell'utente quando si contestualizzano gli LLM per la personalizzazione.

A differenza dei lavori precedenti sulla personalizzazione dell'output dei modelli linguistici di grande dimensione, che si concentrano principalmente sulla modellizzazione *degli interessi* degli utenti, il nostro lavoro si concentra anche sulle loro *conoscenze* relative ad argomenti e ambiti di interesse. Di conseguenza, invece di sfruttare solo le cronologie delle interazioni degli utenti memorizzate in modo lineare, in questo lavoro costruiamo un archivio di conoscenze personali costituito da entità estratte dalle query di ricerca e dalle visite alle pagine. Questo meccanismo, che fornisce una lente attraverso la quale è possibile acquisire le conoscenze degli utenti, presenta due ulteriori vantaggi: consente una personalizzazione leggera grazie al recupero dall'archivio di conoscenze senza richiedere una profilazione esplicita degli utenti [38, 80]; le conoscenze rappresentate come entità sono concise, consentendo così un aumento dell'efficienza grazie alla riduzione della lunghezza del contesto di input rispetto al lavoro di contestualizzazione LLM esistente [58].

Suggerimento di query di ricerca. L'obiettivo del suggerimento di query è quello di raccomandare nuove query di potenziale interesse per gli utenti, sulla base delle query attuali e precedenti all'interno e tra le sessioni di ricerca. Questo compito è sia altamente pratico che utile, essendo stato implementato in motori di ricerca su scala web come Google e Bing, nonché ampiamente applicato ad altri compiti e domini, come la ricerca orientata alle attività [25, 28] e le piattaforme di reclutamento [82]. I primi lavori sul suggerimento delle query hanno utilizzato metodi statistici (probabilistici) basati sulla frequenza, che includono modelli Markov o LDA [11, 33, 37, 50, 72]. Più recentemente, sono stati utilizzati metodi di rete neurale basati su architetture ricorrenti o basate sull'attenzione [12, 23, 34, 66, 81] per modellare meglio le sequenze di query passate e generalizzare a query non viste e a coda lunga. Nel frattempo, altri studi hanno proposto di migliorare le strategie di formazione eseguendo l'apprendimento multi-task con un document ranker [4, 5, 15] o l'apprendimento per rinforzo [8]. Infine, altri lavori recenti [51, 52] utilizzano modelli linguistici pre-addestrati [24, 43] per ottenere prestazioni superiori con una maggiore capacità del modello.

Rispetto ai lavori precedenti sul suggerimento delle query, affrontiamo il compito nuovo ma pratico del suggerimento *contestuale* delle query, in cui i consigli sono ulteriormente condizionati dalla pagina web che l'utente sta visualizzando. Questo compito è notevolmente diverso dal lavoro esistente sul suggerimento delle query che sfrutta le pagine cliccate in precedenza [5, 15, 34, 37] solo attraverso un'associazione superficiale (come le relazioni tra le query passate e i titoli delle pagine), perché

richiede la contestualizzazione dell'intero testo della pagina. Questo nuovo compito è di particolare interesse per noi perché evidenzia la necessità di modelli personalizzati che raccomandino query basate non solo su ciò che interessa agli utenti, ma anche su ciò che *sanno* e quanto ne *sanno*.

3 K-LAMP: LLMs CON CONOSCENZA AUMENTATA PER SUGGERIMENTI DI RICERCA PERSONALIZZATI

In questa sezione, presentiamo il nostro approccio alla generazione di output personalizzati utilizzando un nuovo metodo di aumento della conoscenza per gli LLM e il nostro archivio di conoscenze personali incentrato sulle entità. Descriviamo inoltre in dettaglio la sua applicazione al nuovo compito di suggerimento di query contestualizzate.

3.1 Descrizione del problema

Iniziamo con alcune premesse, introducendo formalmente gli LLM e il problema del suggerimento di query contestuali.

Modelli linguistici di grandi dimensioni. Definiamo un LLM come un modello, parametrizzato da θ , che accetta sia una sequenza di input di token $x = [x_1, x_2, \dots, x_n]$ sia una sequenza supplementare di token contestuali $c = [c_1, c_2, \dots, c_k]$ come prompt, e quindi genera una sequenza di output di token $y = [y(1), y(2), \dots, y(m)]$. Quindi, formalmente, l'inferenza di un LLM può essere rappresentata come: $y \sim \text{LLM}(\theta)(x, c)$. Qui, θ è l'insieme di parametri fissi del modello tipicamente pre-addestrati in modo autoregressivo su corpora di testo massivi; x è un prompt o un insieme di istruzioni emessi dall'utente e dipendenti dall'attività; e c è un contesto aggiuntivo fornito da un sistema ausiliario che aiuta ad aumentare, fondare o migliorare in altro modo la qualità dell'input, in modo che l'LLM sia in grado di generare output y in modo più efficace. Questo documento si concentra in particolare sulla natura di c per l'attività di suggerimento di query contestuali definita di seguito e sull'uso di conoscenze incentrate sulle entità per output più personalizzati.

Suggerimento contestuale di query. Prima di formalizzare il suggerimento contestuale di query, definiamo innanzitutto l'attività di suggerimento di query convenzionale. Sia g_j la query più recente emessa da un utente e $q_{\lambda} = [g_1, g_2, \dots, g_{j-1}]$ una sequenza delle loro query storiche. Quindi, un modello di suggerimento di query QS mira a prevedere nuove query $g_{(j)+1}$ che un singolo utente con la query corrente g_j e la cronologia delle query q_{λ} potrebbe trovare utili. Questo processo può essere riassunto come segue: $g_{(j)+1} = \text{QS}(\theta)(g_j, q_{\lambda})$.

Il suggerimento contestuale di query amplia questa definizione per incorporare un insieme più ampio di contesti $c = [c_1, c_2, \dots, c_k]$ linearizzati come sequenze di testo. Nello specifico, supponiamo innanzitutto che x sia una query di input: $x = g_j$. Quindi, $q_{\lambda} \in c$, il che significa che la cronologia delle query è uno dei segnali contestuali che possono essere sfruttati per il suggerimento delle query. In questo compito, anche il testo di una pagina web w attualmente consultata dall'utente è incluso in c , come segue: $w \in c$. Formalmente, questo compito può essere riassunto come segue: $g_{(j)+1} = \text{QS}(\theta)(x, c)^{(1)}$.

In questo lavoro, cerchiamo di risolvere il problema del suggerimento contestuale delle query

sfruttando un modello arricchito di conoscenze per ottenere risultati più personalizzati. Formalmente, per $g_{j+1} = \text{QS}_{\theta}(x, c)$, impostiamo QS come un LLM (ad esempio, GPT-4 [53]) e includiamo la conoscenza aggregata incentrata sulle entità dalle interazioni storiche degli utenti nel contesto c , al fine di generare raccomandazioni *migliori* $g_{(j)+1}$ misurate da una serie di metriche incentrate sulla personalizzazione (vedere la Sezione 4.3).

¹ Senza il requisito rigido di un documento web di input incluso in c , questa definizione può essere resa più flessibile per includere lavori precedenti sul suggerimento di query *sensibili al contesto* [5, 15, 34, 37].




Figura 2: Panoramica di K-LaMP. Gli input del sistema sono (A) i log di ricerca precedenti e (B) il contesto di ricerca corrente di un utente, che consiste in una query e una pagina web associata. (C) Ogni record di ricerca viene memorizzato in un flusso di memoria insieme a un timestamp. (D) L'archivio di conoscenze basato su entità viene costruito aggregando le entità estratte dal flusso di memoria. (E) K-LaMP, arricchito con entità recuperate dall'archivio di conoscenze personali basato su entità, genera suggerimenti di query compatibili con le conoscenze e gli interessi dell'utente.

3.2 Archivio di conoscenze per la personalizzazione dell'output

Passiamo ora a discutere il nostro framework LLM arricchito di conoscenza per la personalizzazione e descriviamo due istanze di questo framework. Ricordiamo che il contesto supplementare di un LLM c è fornito da fonti o sistemi ausiliari che contribuiscono ad arricchire il prompt di input al modello. In linea con il nostro obiettivo di personalizzare gli output LLM, queste fonti ausiliarie dovrebbero idealmente consistere in dati che catturano le preferenze personali, gli interessi e le conoscenze degli utenti. Pertanto, se K è un archivio di conoscenze che racchiude questi dati specifici dell'utente e $k \in K$ è un sottoinsieme contestualmente rilevante linearizzato come testo, allora, per il suggerimento di query contestuali, il contesto c può essere definito come segue: $c = [q(\lambda) \cdot w \cdot k]$, dove $[\cdot]$ è l'operazione di concatenazione. Data questa formulazione generale, le domande importanti a cui rispondere sono: (1) Come viene costruito l'archivio di conoscenze personali K ? e (2) Come vengono recuperati gli elementi k contestualmente rilevanti dall'archivio di conoscenze K . Rispondiamo a entrambe queste domande di seguito, concentrandoci sulla costruzione nella Sezione 3.2.1 e sul recupero nella Sezione 3.2.2.

3.2.1 Costruzione di archivi di conoscenze personali. Sebbene sia possibile utilizzare una varietà di fonti per costruire un compendio di ciò che interessa e che conosce un utente, in questo documento sfruttiamo le loro cronologie di interazione con un motore di ricerca web. Riteniamo che questa sia una scelta naturale, dato che gli utenti esprimono obiettivi, desideri, interessi e profondità di conoscenza sia esplicitamente che implicitamente attraverso le query emesse, le pagine web cliccate, i contenuti consumati e i modelli comportamentali nel tempo. Si tratta inoltre di una fonte di conoscenza particolarmente rilevante per i suggerimenti contestuali alle query, dove l'obiettivo finale dell'attività è generare suggerimenti di ricerca utili a partire dalla cronologia delle ricerche. Data questa fonte, costruiamo due diverse istanze dell'archivio di conoscenze K : una variante semplice che cattura in modo lineare le query storiche degli utenti e i modelli di navigazione (K_e), e una variante incentrata sulle entità che aggrega gli interessi e le conoscenze personali degli utenti ($K_{(e)}$).

Archivio di conoscenze personali dalla cronologia di ricerca (K_e). L'intuizione alla base di questa istanza dell'archivio di conoscenze K_e è che gli utenti effettuano ricerche e cliccano sulle pagine web che li interessano o che ritengono importanti. E, quando accumulate nel tempo, queste iniziano anche a costruire un quadro di ciò che gli utenti conoscono e di quanto profondamente lo conoscono. Ad esempio, se un utente effettua più query nel tempo che includono "Machine Learning", "ML", "Ottimizzazione", "SGD",

"Deep Learning" e clicca su una serie di pagine web risultanti da queste query, possiamo supporre che questo utente abbia almeno familiarità con il concetto generale di "Machine Learning".

Per rendere operativa questa intuizione, costruiamo un flusso di memoria con indicazione temporale composto dalle query inviate dagli utenti e dalle pagine web associate ai risultati su cui hanno cliccato (vedi Figura 2). Si noti che si tratta di un'istanza estremamente leggera dell'archivio di conoscenze, essendo solo una visione parziale delle azioni e delle interazioni degli utenti già registrate dai moderni motori di ricerca su scala web. Di conseguenza, non vi sono problemi di privacy o scalabilità oltre a quelli già inerenti al sistema di registrazione del motore di ricerca.

Archivio di conoscenze incentrato sull'entità personale ($K_{(e)}$). Sebbene la creazione di un flusso di memoria basato sulle cronologie di ricerca degli utenti sia semplice, esistono alcune limitazioni derivanti dalla sua progettazione. In primo luogo, poiché le query di ricerca e le visite alle pagine web vengono archiviate e recuperate in modo lineare, è difficile eseguire aggregazioni al volo. Tuttavia, tale aggregazione può essere molto utile per la personalizzazione. Ad esempio, sapere che un utente ha cliccato più volte su pagine web associate al "Machine Learning", mentre ha cliccato solo su una singola pagina web derivante dalla query "Biologia computazionale", tenderebbe a indicare una maggiore affinità e conoscenza dell'argomento del machine learning. Altre questioni includono il fatto che le singole pagine web visitate da un utente possono contenere una combinazione di diversi argomenti e domini, distraendo gli LLM nella generazione di output coerenti con il contesto, e il fatto che l'inclusione di grandi quantità di testo da pagine web lunghe rende l'utilizzo degli LLM lento e costoso.

Per affrontare queste preoccupazioni, costruiamo un'istanza incentrata sulle entità dell'archivio di conoscenze K_e (vedi Figura 2). Le entità sono atomi utili per catturare gli interessi e le conoscenze degli utenti perché consistono nei nomi (propri o meno) che descrivono le persone, i luoghi, le organizzazioni, gli argomenti e i domini che interessano e che gli utenti conoscono. Inoltre, poiché tendono ad essere relativamente brevi e facili da aggregare, e poiché il riconoscimento e il collegamento delle entità [18, 41] sono problemi ben studiati, il processo di operatività della creazione di questo archivio è notevolmente semplificato.

Utilizziamo un sistema di collegamento delle entità all'avanguardia e pronto all'uso [19] per taggare e canonizzare le entità che compaiono nelle query di ricerca e nelle pagine web associate visitate dagli utenti. Mentre

le singole occorrenze delle entità nell'archivio di conoscenza sono contrassegnate da un timestamp, un'ulteriore aggregazione viene effettuata contando il numero di occorrenze delle entità nelle cronologie complete delle interazioni degli utenti.

Sebbene questa istanza di archivio di conoscenza incentrata sulle entità K_e possa non essere minimalista come K_e , è comunque relativamente leggera se confrontata con i sistemi che personalizzano attraverso la costruzione di profili approfonditi. La soluzione è scalabile poiché l'unica dipendenza esterna è un collegamento di entità esistente, che in genere può elaborare migliaia di token al secondo. Inoltre, anche le preoccupazioni relative alla privacy sono minime, poiché il collegamento delle entità proietta e aggrega le menzioni nel testo su sottografi di basi di conoscenza pubbliche (ad esempio Wikipedia). L'aggregazione delle occorrenze delle entità si presta naturalmente a pratiche comuni di mitigazione della privacy come la k -anonimizzazione [61]. Inoltre, i record possono essere facilmente rimossi su richiesta, semplicemente eliminando le entità associate dall'archivio.

3.2.2 Recupero contestuale da archivi di conoscenza personali. Passiamo ora alla questione del recupero di elementi contestualmente rilevanti k da un archivio di conoscenza K , condizionati da una query di input q_j e da un documento w con cui l'utente sta attualmente interagendo. Una fase di recupero attentamente ponderata è essenziale per aumentare la capacità degli LLM di produrre output personalizzati, poiché basa la generazione sugli interessi storici e sulle conoscenze degli utenti. Di seguito, mostriamo come viene eseguito il recupero per entrambe le istanze dell'archivio di conoscenze $K_{(e)}$ e $K_{(f)}$ descritte nella Sezione 3.2.1.

Nel caso di K_e sulla cronologia di ricerca e navigazione degli utenti, il recupero viene effettuato trovando e restituendo le query più simili e le pagine web visitate in precedenza all'input corrente x . In pratica, le query vengono poi eliminate da questo risultato poiché offrono pochi vantaggi rispetto al testo molto più lungo presente nelle pagine web. Per rendere operativa la fase di recupero, rappresentiamo innanzitutto tutti i record nell'archivio di conoscenze $K_{(e)}$ utilizzando gli embedding, quindi calcoliamo le somiglianze a livello di embedding con la rappresentazione della query corrente $g_{(j)}$ utilizzando Contriever [42]. Infine vengono restituiti i record k più simili.

Nel frattempo, per l'archivio di conoscenze incentrato sulle entità K_e , il recupero è condizionato dalle entità presenti nella query corrente g_j e nella pagina web w , che vengono ulteriormente confrontate con K_e . Dato che le entità sono unità atomiche con conteggi e timestamp associati, il processo di corrispondenza e recupero può essere reso operativo in modi flessibili (vedi Figura 2). Esploriamo in particolare tre strategie per l'abbinamento delle entità: familiari (entità incontrate frequentemente dall'utente), non familiari (entità che l'utente ha incontrato raramente o mai) e scadute (entità che l'utente incontrava in precedenza ma che non ha più incontrato di recente). Nello specifico, per le entità familiari, ordiniamo le entità che compaiono nel contesto di ricerca $[x \cdot w]$ in base alla frequenza di occorrenza nell'archivio di conoscenza $K_{(e)}$, quindi campioniamo 5 entità in proporzione alla loro frequenza. Per le entità non familiari, viene utilizzato un processo simile per il campionamento, tranne per il fatto che le entità vengono ordinate in modo inverso rispetto alla loro occorrenza in $K_{(e)}$. Infine, per le entità scadute, iniziamo filtrando le entità in $[x \cdot w]$ in base al timestamp per conservare solo quelle che compaiono in $K_{(e)}$, ma che non sono state utilizzate nelle due settimane precedenti. Quindi campioniamo da questo insieme filtrato di entità in base alla frequenza, proprio come facciamo con le entità familiari.

4 IMPOSTAZIONE SPERIMENTALE

In questa sezione descriviamo i set di dati e i modelli utilizzati nella nostra configurazione di valutazione, nonché i dettagli di implementazione.

4.1 Dati

Utilizziamo registri di ricerca reali su larga scala provenienti dal motore di ricerca Bing [2]. Nello specifico, campioniamo tre mesi di registri di ricerca, dal 1° maggio 2023 al 31 luglio 2023. Quindi filtriamo e campioniamo questo set di dati per renderlo adatto alla valutazione del nostro compito, che comprende i seguenti passaggi. In primo luogo, poiché il compito che stiamo affrontando è il suggerimento di query contestuali, ovvero raccomandazioni basate sulla pagina web che l'utente sta visualizzando, filtriamo le sessioni che non contengono risultati di ricerca cliccati. Filtriamo ulteriormente i dati per scartare gli eventi di clic che portano a pagine in domini diversi da Wikipedia o da un insieme curato di 500 siti di pubblicazione di notizie ad alto traffico. Lo facciamo perché il linker di entità [19] che utilizziamo mappa su Wikipedia e vogliamo massimizzare le possibilità di incontrare entità collegate. Vale la pena notare che K-LaMP stesso è agnostico rispetto alla scelta del linker o del suo grafico di conoscenza sottostante, e il nostro approccio potrebbe essere facilmente applicato a un dominio diverso, ad esempio utilizzando un linker su un grafico di prodotti per lo shopping. Infine, filtriamo i dati rimanenti per scartare gli utenti che hanno effettuato meno di 100 visite alla pagina in tre mesi, che riteniamo essere utenti che effettuano ricerche poco frequenti. Inoltre, eseguiamo e applichiamo controlli e filtri di privacy a livello aziendale, come l'utilizzo di query di ricerca richieste da almeno 50 individui, per garantire che i dati rimangano adeguatamente anonimizzati. I dati risultanti sono ancora estremamente voluminosi; pertanto, campioniamo ulteriormente in modo casuale un sottoinsieme di 1.000 utenti al fine di ottenere il set di riferimento che costituisce la base per tutte le valutazioni che effettuiamo in questo documento (Sezione 4.3). Questo set di dati finale contiene in media 493 query, 109 sessioni, 177 articoli cliccati e 3.053 entità incontrate per utente. Ai fini del test, abbiamo suddiviso il set di dati e riservato le 10 sessioni più recenti di ogni utente come obiettivi di previsione per i suggerimenti di query contestuali, utilizzando tutte le sessioni precedenti per creare archivi di conoscenza personali basati sulla ricerca e la navigazione ($K_{(e)}$) e incentrati sulle entità ($K_{(f)}$)

per gli utenti, come descritto nella Sezione 3.2.1.

4.2 Linee di base e il nostro modello

Confrontiamo il nostro approccio agli LLM con conoscenza aumentata per la personalizzazione dell'output con diversi baselines rilevanti che forniscono suggerimenti di query basati sul contesto di ricerca degli utenti. Notiamo che, per un confronto più equo, tutti i baselines e il nostro modello utilizzano LLM (in particolare GPT-4) per fornire suggerimenti di query. In particolare, non includiamo nei nostri esperimenti principali approcci di suggerimento di query basati su tecniche di modellazione più datate (ad esempio, RNN o BART [51, 66]) a causa della loro limitata capacità di comprendere contesti più lunghi e input di dati complessi, in particolare senza dati di addestramento dedicati (il framework che proponiamo non ne necessita). Inoltre, queste tecniche di suggerimento delle query non sono progettate per gestire contesti più lunghi, come la pagina web che un utente sta attualmente visualizzando, rendendo così un confronto diretto banalmente rilevante nella migliore delle ipotesi. Tuttavia, per completezza, abbiamo incluso alcuni confronti aneddotici nell'Appendice B.

I modelli valutati in questo lavoro sono elencati di seguito: (1) **Suggerimento di query** – che utilizza una query corrente g_j e query storiche da q_{λ} nella stessa sessione per suggerire la query successiva g_{j+1} ; (2) **Suggerimento di query contestuale** – simile al suggerimento di query, ma che condiziona ulteriormente la raccomandazione della query successiva $g_{(j+1)}$ su una pagina web w , cliccata come risultato della query corrente $g_{(j)}$; (3) **Suggerimento di query contestuale con $K_{(e)}$** – che include

Tabella 1: Risultati principali relativi al nostro compito di suggerimento di query contestuale. I risultati migliori sono evidenziati in grassetto.

Tipi	Modelli	Validità ($\uparrow$)	Correlazione ($\uparrow$)	Utilità ($\uparrow$)	Classifica ($\downarrow$)
Linee di base	Suggerimento query	1,769	0,962	0,948	2,736
	Suggerimenti contestuali per le query	1,966	1,267	1,245	2,415
	Suggerimenti contestuali per le query con K_e	1,822	1,192	1,166	2,654
Il nostro	K-LaMP (nostro)	1,966	1,482	1,455	2,160

recuperi dall'archivio di conoscenze K_e sulle attività storiche di ricerca e navigazione degli utenti, come contesto aggiuntivo per personalizzare i risultati dell'LLM; (4) **K-LaMP** – che è il nostro modello completo che potenzia gli LLM con conoscenze incentrate sulle entità provenienti dall'archivio di conoscenze

memorizza K_e al fine di eseguire suggerimenti di query contestuali.

4.3 Configurazione della valutazione

Per valutare l'efficacia dei diversi modelli di suggerimento delle query nella generazione di output personalizzati, è necessario un parametro di valutazione adeguato.

idealmente dovrebbe non solo rilevare se le query suggerite sono contestualmente rilevanti, ma anche se sono in linea con gli interessi e le conoscenze dell'utente. Dato che il suggerimento contestuale delle query è un problema nuovo che proponiamo in questo articolo, non esistono metriche di valutazione disponibili per questo compito. In particolare, le metriche per la valutazione dei suggerimenti di query convenzionali non sono applicabili in questo caso perché non tengono conto dell'intero *contesto* presente nel nostro compito, ovvero il documento di input utilizzato dall'utente. Pertanto, ci affidiamo alla valutazione umana per misurare e confrontare i diversi modelli sul nostro benchmark sperimentale.

Vale la pena notare che la valutazione umana di qualsiasi forma di personalizzazione è difficile, poiché la persona che esegue la valutazione raramente è la persona da cui provengono i dati. A meno di non testare il nostro sistema in un contesto reale (un'impresa ingegneristica che va ben oltre lo scopo dell'esplorazione scientifica di questo articolo), qualsiasi valutazione del nostro compito e del nostro set di dati deve essere limitata da questo vincolo. Ciononostante, cerchiamo di fornire agli annotatori quante più informazioni possibili per comprendere sia il contesto di ricerca attuale dell'utente sia i suoi interessi e conoscenze personali (vedere la tabella 6 per un esempio). In particolare, per riassumere il contesto di ricerca attuale per gli annotatori, mostriamo loro le query di ricerca attuali e precedenti di un utente in una determinata sessione, la pagina web su cui l'utente ha cliccato dopo aver effettuato la query di ricerca attuale e un elenco di 20 entità di tendenza che catturano i picchi statistici nel volume di ricerca tra gli utenti. Inoltre, al fine di presentare una sintesi degli interessi personali e delle conoscenze degli utenti, mostriamo agli annotatori un elenco delle 30 entità più frequenti dall'archivio di conoscenze personale incentrato sulle entità dell'utente, nonché un riepilogo generato da GPT-4 da queste entità che indica quali argomenti o domini l'utente potrebbe conoscere o a cui potrebbe essere particolarmente interessato.

Presentati questi dati e le query consigliate dalle diverse linee di base e dal nostro modello (in cui i nomi dei sistemi sono oscurati agli annotatori), a un giudice umano viene chiesto di valutare le seguenti tre metriche su una scala Likert a 3 punti²: (1) **Validità**: se una query di output può essere inserita in un motore di ricerca e se ci si può aspettare che produca risultati pertinenti; (2) **Attinenza**: se la query di output è strettamente correlata agli interessi personali dell'utente

Tabella 2: Risultati degli accordi tra annotatori su tutti i risultati dei suggerimenti di query valutati da annotatori umani.

Accordi	Metriche	Punteggi ($\uparrow$)
	Validità	0,963
Corrispondenza esatta	Correlazione	0,850
	Utilità	0,819
Coefficiente kappa di Cohen	Validità	0,606
	Correlazione	0,652
	Utilità	0,622
Coefficiente di correlazione di Spearman	Classifica	0,654

e conoscenza; e (3) **Utilità**: se l'utente è propenso a cliccare sulla query di output, dati i suoi interessi e le sue conoscenze storiche, nonché il contesto di ricerca attuale. Infine, chiediamo agli annotatori anche una quarta misura: (4) **Classifica**: dove gli output dei diversi sistemi sono classificati in base all'ordine in cui è probabile che vengano cliccati, in base alla loro affinità con gli interessi, le conoscenze e il contesto di ricerca dell'utente. Nel loro insieme, questi quattro parametri di valutazione catturano non solo la qualità dei diversi suggerimenti di query, sia individualmente che in relazione tra loro, ma anche il loro grado di allineamento con gli aspetti *personali* del nostro compito di valutazione, ovvero ciò che interessa e ciò che conoscono gli utenti.

Per eseguire le valutazioni con giudici umani, abbiamo reclutato 12 annotatori in India tramite una società fornitrice terza [3]. A loro è stato fornito un documento guida che includeva istruzioni per l'attività, metriche e alcuni esempi annotati, e sono stati pagati 11,98 dollari all'ora per il tempo dedicato all'attività. Dopo diversi cicli di valutazione e perfezionamento, abbiamo ottenuto i risultati della valutazione manuale per 1.309 set di risultati di suggerimenti di query contestuali da tutti e quattro i modelli elencati nella sezione 4.2 (effettivamente un totale di 5.236 annotazioni per singoli suggerimenti di query).

Inoltre, al fine di convalidare la qualità delle annotazioni e misurare la concordanza tra gli annotatori, circa il 27% dei dati è stato annotato da due valutatori umani. Nello specifico, per quanto riguarda la validità, la pertinenza e l'utilità, abbiamo misurato un punteggio di corrispondenza esatta, che verifica la frequenza con cui gli annotatori assegnano lo stesso punteggio su una scala Likert a 3 punti, e il coefficiente kappa di Cohen [17], che tiene conto anche della concordanza casuale. Per il ranking, riportiamo il coefficiente di correlazione di Spearman [1], che misura la correlazione tra due insiemi di sistemi classificati, calcolata come media tra coppie di utenti e istanze di dati. Come mostrato nella tabella 2, osserviamo che la concordanza tra gli annotatori è da moderata ad alta, indicando che i giudici sono effettivamente in grado di prendere decisioni ragionevolmente informate sui suggerimenti di query contestuali personalizzati dai dati che forniamo loro. Infine, per quanto riguarda i dettagli di implementazione, utilizziamo la versione GPT-4 [53] del 13 giugno 2023 come base per i suggerimenti di query in tutte le linee di base e le varianti del modello, al fine di garantire un confronto equo. Abbiamo impostato il

² La scala Likert a 3 punti è composta da d'accordo (2), neutro (1) e in disaccordo (0).

Tabella 3: Risultati di diverse strategie di recupero sulla pertinenza del recupero rispetto al contesto di ricerca corrente dell'utente.

Tipi di recupero	Tipi	Rilevanza del recupero (t)
Recupero basato sulla cronologia (K_e)	Documenti passati	0,299
Ricerca incentrata sulle entità (K_e)	Entità familiari	0,936
	Entità non familiari	0,810
	Entità scadute	0,849

Iperparametri di GPT-4 con temperatura = 0,7 e $\text{top}_p = 0,95$. Il linker di entità utilizzato per costruire le istanze dell'archivio di conoscenze è NEMO [18, 19]³. I prompt utilizzati per ottenere risposte da GPT-4 per i suggerimenti di query sono riportati nell'Appendice A.

5 RISULTATI SPERIMENTALI

Presentiamo ora l'insieme dei risultati sperimentali della nostra valutazione e riportiamo i risultati di vari studi e analisi ausiliari.

I nostri risultati principali sono riportati nella Tabella 1. Ciò conferma che il nostro

Il framework K-LaMP supera costantemente e in modo significativo tutti gli altri

altre linee di base in termini di correlazione, utilità e metriche di classificazione. Sebbene sia alla pari con il suggerimento contestuale delle query in termini di validità, questo risultato è nel complesso positivo, anche se in qualche modo prevedibile, poiché, intuitivamente, l'inclusione del contesto personale non porta necessariamente a query più *valide* per il recupero da parte dei motori di ricerca. Nel frattempo, da questa tabella è possibile ricavare alcune altre interessanti informazioni. Il suggerimento contestuale delle query con K_e non supera il suggerimento contestuale delle query. Ipotizziamo che ciò sia dovuto al fatto che le informazioni recuperate dalla memoria (K_e) hanno scarsa rilevanza per il contesto di ricerca corrente, portando ad aumenti spuri che distraggono piuttosto che aiutare l'LLM.

Per approfondire questa ipotesi, conduciamo una valutazione supplementare, in cui chiediamo ad annotatori umani di valutare le informazioni recuperate dagli archivi di conoscenza per un particolare contesto di ricerca (vedere la sezione 3.2.2 per i dettagli). Nello specifico, riportiamo la rilevanza del recupero da entrambe le istanze dei nostri archivi di conoscenza nella Tabella 3. Questa metrica è il punteggio medio di una domanda Sì/No: se il contesto recuperato è rilevante per il contesto di ricerca corrente (1) o meno (0). Come mostrato nella Tabella 3, la qualità dei recuperi dall'archivio di conoscenza incentrato sulle entità è superiore a quella dei recuperi dall'archivio basato sulla cronologia di ricerca lineare. Questo perché abbiamo un controllo molto maggiore con le entità che sono le unità atomiche dello spazio di rappresentazione della conoscenza e siamo in grado di abbinare *esattamente* le entità nel contesto con quelle nell'archivio, piuttosto che affidarci a un processo di recupero basato sulla somiglianza fuzzy con un recuperatore denso basato sull'incorporamento [42].

5.1 Studi e analisi aggiuntivi

Ablazione sulle strategie di corrispondenza delle entità. Ricordiamo che K-LaMP si basa su una combinazione di corrispondenza e recupero di diversi tipi di entità dal suo archivio di conoscenze incentrato sulle entità, ovvero: entità familiari, non familiari e scadute (vedere la sezione 3.2.2). Al fine di misurare individualmente il contributo di ciascuna strategia, generiamo suggerimenti di query arricchiti di conoscenza su 313 contesti di ricerca utilizzando un solo tipo di entità e chiediamo ad annotatori umani di valutare i risultati in base a validità, pertinenza e utilità. I risultati comparativi sono presentati nella Figura 3. In primo luogo, essi ribadiscono il fatto

³ Evitiamo i più recenti linker di entità basati su LM [21, 41] poiché hanno limiti restrittivi di token di input che spesso vengono superati dagli input nel nostro scenario.




Figura 3: Risultati delle varianti di K-LaMP sulla strategia di recupero delle conoscenze personalizzate e risultati senza recupero.




Figura 4: Risultati delle linee di base e di K-LaMP con un numero diverso di query precedenti query precedenti (ovvero diverse dimensioni di memoria).

che la validità è praticamente invariante rispetto alla scelta dell'acquisizione di conoscenze, poiché le informazioni personali non influenzano la validità di una query. Le metriche di correlazione e utilità, tuttavia, sono chiaramente influenzate dalla scelta della strategia di corrispondenza delle entità in modo coerente. In particolare, l'utilizzo esclusivo di entità "non familiari" produce i punteggi più alti in entrambe le metriche, superando persino il modello K-LaMP completo. Ciò sembra suggerire che le query derivanti da entità nuove (per l'utente), che incoraggiano implicitamente l'esplorazione, sono preferite rispetto alle query che rivisitano terreni familiari. Sebbene questi risultati siano veritieri per questi dati, notiamo che gli utenti reali possono avvicinarsi alla ricerca sul web con obiettivi diversi in mente: come la ricerca, l'esplorazione o la revisione, ed è difficile per i giudici valutare questi obiettivi da dati limitati, sebbene ricchi. Di conseguenza, riteniamo che un approccio globale per cogliere le diverse visioni della conoscenza degli utenti, in modo che possa essere approfondita, ampliata o rivitalizzata a seconda delle esigenze del caso d'uso, sia una strategia solida.

Analisi della lunghezza della cronologia delle interazioni. Un presupposto fondamentale nella nostra configurazione per la personalizzazione dell'output LLM è che possiamo conoscere gli utenti mentre interagiscono con i motori di ricerca. Una domanda naturale che segue questo presupposto è come cambia la performance dei sistemi che si basano sulla conoscenza personale in funzione della lunghezza della cronologia delle interazioni. Per rispondere a questa domanda, abbiamo condotto un'analisi con cronologie di durata variabile e riportato i risultati nella Figura 4. Da questa analisi osserviamo nuovamente che la validità non è influenzata dalla lunghezza della cronologia delle interazioni, mentre la pertinenza e l'utilità lo sono. In particolare, K-LaMP è l'unico modello che mostra un miglioramento costante con cronologie delle interazioni più lunghe, dimostrando la sua capacità di arricchire nel tempo le rappresentazioni degli interessi e delle conoscenze personali. Una spiegazione ragionevole di questo incremento è l'aggregazione che avviene nell'archivio di conoscenze incentrato sulle entità di K-LaMP, che contrasta con le cronologie archiviate in modo lineare degli altri approcci.

Analisi utilizzando diversi LLM. Infine, conduciamo un'analisi ausiliaria per vedere come cambia la qualità dei consigli di query da diversi sistemi se si utilizza un LLM diverso da GPT-4. Nello specifico, utilizziamo la versione del 13 giugno 2023 di GPT-3.5-Turbo come LLM

Tabella 4: Risultati con diversi LLM: GPT-3.5 e GPT-4.

Metodi	LLM	Validità	Correlazione	Utilità
Suggerimenti per le query	GPT-3.5	1,767	1,077	1,069
	GPT-4	1,747	1,080	1,060
Suggerimento di query contestuale	GPT-3.5	1,967	1,177	1,202
	GPT-4	1,987	1,367	1,313
K-LaMP (nostro)	GPT-3.5	2,000	1,279	1,303
	GPT-4	1,983	1,653	1,600

su 128 set di suggerimenti di query provenienti da due linee di base (Query Suggestion e Contextual Query Suggestion) e dal nostro framework K-LaMP, e confrontiamo i risultati con GPT-4; questi sono riportati nella Tabella 4. In primo luogo, Query Suggestion è indipendente dalla scelta degli LLM, mentre Contextual Query Suggestion e K-LaMP non lo sono. Ciò è probabilmente dovuto al fatto che questi ultimi due approcci devono incorporare informazioni provenienti da pagine web complete come contesto e quindi beneficiano delle capacità rappresentative, di ragionamento e generative del modello più grande. Più rilevante per i contributi di questo articolo, abbiamo riscontrato che, anche con GPT-3.5-Turbo, K-LaMP mostra prestazioni comparabili sulla metrica dell'utilità con il secondo miglior modello, il suggerimento contestuale delle query, nonostante quest'ultimo utilizzi GPT-4. Ciò dimostra il vantaggio significativo che una rappresentazione incentrata sull'entità degli interessi e delle conoscenze personali di un utente offre per la personalizzazione potenziata dalla conoscenza dei risultati degli LLM, con un'elevata efficienza nell'implementazione di K-LaMP nelle applicazioni del mondo reale.

5.2 Configurazione della valutazione automatica

Sebbene la valutazione umana sia utile per misurare i sistemi e ottenere informazioni approfondite, soprattutto su un nuovo compito come quello che introduciamo, il processo è lento e costoso e quindi non scalabile a set di dati più grandi o estensioni future. Per affrontare questi problemi, esploriamo una serie iniziale di metriche di valutazione automatica che rispecchiano quelle descritte nella Sezione 4.3 e che possono essere utilizzate in assenza di giudizio umano. Ricordiamo che anche la valutazione umana per attività che riguardano la personalizzazione non è banale; pertanto, valutare automaticamente i risultati di un sistema di query contestuale condizionandolo a complesse preferenze personali e dati di conoscenza è molto difficile. Ciononostante, proponiamo e sperimentiamo le seguenti formulazioni automatiche: (1) **Validità**: calcoliamo la somiglianza tra l'output del suggerimento di query di un sistema e il primo risultato di ricerca (titolo e snippet) restituito dall'invio di tale query al motore di ricerca web (per vedere se la query produce risultati di ricerca ragionevoli); (2) **Correlazione**: misuriamo la somiglianza tra il suggerimento di query e l'insieme di entità personali contestuali recuperate dall'archivio di conoscenze incentrato sulle entità dell'utente (per garantire che la query sia fondata sul contesto personale dell'utente); (3) **Utilità**: calcoliamo la somiglianza tra il suggerimento di query e le query reali successive che l'utente ha finito per inviare (al fine di confrontare i consigli con le azioni reali dell'utente). In ciascuna di queste tre metriche⁽⁴⁾ la somiglianza viene calcolata calcolando il prodotto scalare delle rappresentazioni ottenute da Contriever [42].

Convalidiamo queste metriche di valutazione automatica classificando i sistemi sul set di test, quindi calcolando la correlazione di Spearman rispetto alla classifica ottenuta dai punteggi di giudizio umano. Come mostrato

Tabella 5: Risultati con metriche di valutazione automatiche.

Tipi	Validità	Correlazione	Utilità
Correlazione con la valutazione umana	0,445	0,397	-0,016
Suggerimento query	1,784	1,189	0,882
Suggerimento di query contestuale	1,891	1,340	0,831
Suggerimenti contestuali per le query con K	1,828	1,271	0,847
K-LaMP (nostro)	1,910	1,472	0,845

nella tabella 5, troviamo una correlazione moderata su validità e pertinenza, indicando che le metriche automatiche da noi proposte per queste misure possono essere utilizzate come proxy in assenza di etichettatura umana. Tuttavia, non vi è alcuna correlazione tra le metriche automatiche e quelle umane di utilità. Ciò è prevedibile, poiché non ci si aspetta che i consigli (contestuali) relativi alle query siano perfettamente allineati con il comportamento effettivo degli utenti, che è alla base della nostra formulazione per il calcolo automatico dell'utilità; gli utenti *dovrebbero* essere sorpresi e soddisfatti dai suggerimenti a cui non avrebbero altrimenti pensato.

Esistono diversi modi per migliorare il processo di valutazione automatica dei suggerimenti contestuali delle query. Ad esempio, potremmo utilizzare un altro LLM per eseguire una valutazione basata su criteri di validità, pertinenza e utilità, sfruttando la sua capacità di tenere conto di dati personali e preferenziali complessi. Oppure potremmo addestrare versioni parametrizzate delle metriche automatiche che abbiamo proposto su dati etichettati manualmente con l'obiettivo di aumentare la correlazione con il giudizio umano. Lasciamo queste e altre esplorazioni a lavori futuri.

6 CONCLUSIONE

In questo lavoro abbiamo proposto un framework di aumento della conoscenza per la personalizzazione dell'output LLM chiamato K-LaMP, che sfrutta le interazioni storiche degli utenti con un motore di ricerca. Il nucleo della conoscenza personale che abbiamo utilizzato per l'aumento LLM si basa su un nuovo archivio di conoscenza personale leggero e incentrato sulle entità, costruito a partire dalle query emesse dagli utenti e dalle pagine web che hanno visualizzato durante la ricerca e la navigazione sul web. Per testare il nostro framework di personalizzazione, ci siamo concentrati sul nuovo compito di suggerimento contestuale delle query di ricerca, che richiede in modo cruciale la modellizzazione sia degli interessi contestuali che delle conoscenze degli utenti. Attraverso la valutazione umana su un ampio set di test, abbiamo dimostrato che il nostro LLM potenziato dalla conoscenza incentrata sulle entità produce raccomandazioni di query personalizzate che sono più correlate all'intento degli utenti, più utili e costantemente classificate al di sopra di quelle prodotte da diversi altri modelli di suggerimento di query basati su LLM. I nostri risultati dimostrano che le entità sono unità atomiche efficaci per la rappresentazione della conoscenza personale, offrendo un solido compromesso tra prestazioni, flessibilità, privacy e scalabilità, rispetto ad altri approcci di personalizzazione che si basano sulla creazione di profili approfonditi o sulla semplice linearizzazione delle interazioni storiche di un utente. Riteniamo che K-LaMP abbia il potenziale per influenzare sia la ricerca futura che l'innovazione dei prodotti. L'uso dell'aumento personalizzato delle conoscenze per altre attività di ricerca, come la generazione di snippet o la risposta a domande, l'integrazione di altre fonti di dati, come la cronologia degli acquisti o dei consumi multimediali, e l'applicazione a settori al di fuori della ricerca, come gli assistenti personali AI, sono tutte interessanti possibilità di lavoro futuro. Allo stesso tempo, una valutazione migliorata rimane un importante obiettivo futuro, con metriche automatiche migliorate e l'implementazione nel mondo reale come potenziali direzioni da esplorare.

⁴ Non specifichiamo una misura automatica della classificazione, poiché ciò può essere fatto in modo banale assegnando un punteggio e quindi ordinando i sistemi in base a una o più delle altre metriche automatiche.

RIFERIMENTI

- [1] 2008. *Coefficiente di correlazione di Spearman*. 502–505.
- [2] 2023. *Ricerca Bing*. <https://www.bing.com/>
- [3] 2023. *KarmaHub*. <https://www.mykarmahub.com/>
- [4] Wasi Uddin Ahmad, Kai-Wei Chang e Hongning Wang. 2018. Apprendimento multi-task per il ranking dei documenti e i suggerimenti di query. In *6a Conferenza internazionale sull'apprendimento delle rappresentazioni, ICLR 2018, Vancouver, BC, Canada, 30 aprile-3 maggio 2018, Atti della conferenza*.
- [5] Wasi Uddin Ahmad, Kai-Wei Chang e Hongning Wang. 2019. Classificazione dei documenti e suggerimenti di ricerca basati sul contesto tentativo Document Ranking and Query Suggestion. In *Atti della 42a Conferenza internazionale ACM SIGIR sulla ricerca e lo sviluppo nel recupero delle informazioni, SIGIR 2019, Parigi, Francia, 21-25 luglio 2019*. ACM, 385–394.
- [6] Rohan Anil, Andrew M. Dai, Orhan Firat, Melvin Johnson, Dmitry Lepikhin, Alexandre Passos, Siamak Shakeri, Emanuel Taropa, Paige Bailey, Zhifeng Chen, Eric Chu, Jonathan H. Clark, Laurent El Shafey, Yanping Huang, Kathy Meier-Hellstern, Gaurav Mishra, Erica Moreira, Mark Omernick, Kevin Robinson, Sebastian Ruder, Yi Tay, Kefan Xiao, Yuanzhong Xu, Yujing Zhang, Gustavo Hernández Abrego, Junwhan Ahn, Jacob Austin, Paul Barham, Jan A. Borchers, James Bradbury, Siddhartha Brahma, Kevin Brooks, Michele Catasta, Yong Cheng, Colin Cherry, Christopher A. Choquette-Choo, Aakanksha Chowdhery, Clément Crepey, Shachi Dave, Mostafa Dehghani, Shunyu Dev, Jacob Devlin, Mark Diaz, Nan Du, Ethan Dyer, Vladimir Feinberg, Fangxiaoyu Feng, Vlad Fienber, Markus Freitag, Xavier Garcia, Sebastian Gehrmann, Lucas Gonzalez, et al. 2023. PaLM 2 Technical Report. *Preprint arXiv arXiv:2305.10403* (2023).
- [7] Jinheon Baek, Alham Fikri Aji e Amir Saffari. 2023. Modello linguistico potenziato dalla conoscenza per la risposta a domande su grafici di conoscenza zero-shot. In *Atti del 1° Workshop sul ragionamento in linguaggio naturale e le spiegazioni strutturate (NLRSE)*. Associazione per la linguistica computazionale.
- [8] Praveen Kumar Bodigutla. 2021. Suggerimenti di query di ricerca correlate di alta qualità utilizzando l'apprendimento rinforzato profondo. *Preprint arXiv arXiv:2108.04452* (2021).
- [9] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever e Dario Amodei. 2020. I modelli linguistici sono apprenditori few-shot. In *Advances in Neural Information Processing Systems 33: Conferenza annuale sui sistemi di elaborazione delle informazioni neurali 2020, NeurIPS 2020, 6-12 dicembre 2020, virtuale*.
- [10] Jin Chen, Zheng Liu, Xu Huang, Chenwang Wu, Qi Liu, Gangwei Jiang, Yuanhao Pu, Yuxuan Lei, Xiaolong Chen, Xingmei Wang, Defu Lian e Enhong Chen. 2023. Quando i modelli linguistici di grandi dimensioni incontrano la personalizzazione: prospettive dell', sfide e opportunità. *Preprint arXiv arXiv:2307.16376* (2023).
- [11] Wanyu Chen, Fei Cai, Honghui Chen e Maarten de Rijke. 2017. Diversificazione dei suggerimenti di query personalizzati. In *Atti della 40a Conferenza internazionale ACM SIGIR sulla ricerca e lo sviluppo nel recupero delle informazioni, Shinjuku, Tokyo, Giappone, 7-11 agosto 2017*. ACM, 817–820.
- [12] Wanyu Chen, Fei Cai, Honghui Chen e Maarten de Rijke. 2018. Suggerimenti di query neurali gerarchici basati sull'attenzione. In *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval, SIGIR 2018, Ann Arbor, MI, USA, 8-12 luglio 2018*. ACM, 1093–1096.
- [13] Wei-Fan Chen, Shahbaz Syed, Benno Stein, Matthias Hagen e Martin Potthast. 2020. Generazione di snippet astratti. In *WWW '20: The Web Conference 2020, Taipei, Taiwan, 20-24 aprile 2020*. ACM / IW3C2, 1309–1319.
- [14] Zheng Chen. 2023. PALR: Personalization Aware LLMs for Recommendation. *Preprint arXiv arXiv:2305.07622* (2023).
- [15] Qiannan Cheng, Zhaochun Ren, Yujie Lin, Pengjie Ren, Zhumin Chen, Xiangyuan Liu e Maarten de Rijke. 2021. Ricerca di sessioni a lungo termine: riclassificazione personalizzata congiunta e previsione della query successiva. In *WWW '21: The Web Conference 2021, evento virtuale / Lubiana, Slovenia, 19-23 aprile 2021*. ACM / IW3C2, 239–248.
- [16] Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, Parker Schuh, Kensen Shi, Sasha Tsvyashchenko, Joshua Maynez, Abhishek Rao, Parker Barnes, Yi Tay, Noam Shazeer, Vinodkumar Prabhakaran, Emily Reif, Nan Du, Ben Hutchinson, Reiner Pope, James Bradbury, Jacob Austin, Michael Isard, Guy Gur-Ari, Pengcheng Yin, Toju Duke, Anselm Levskaya, Sanjay Ghemawat, Sunipa Dev, Henryk Michalewski, Xavier Garcia, Vedant Misra, Kevin Robinson, Liam Fedus, Denny Zhou, Daphne Ippolito, David Luan, Hyeontaek Lim, Barret Zoph, Alexander Spiridonov, Ryan Sepassi, David Dohan, Shivan Agrawal, Mark Omernick, Andrew M. Dai, Thanumalayan Sankaranarayanan Pillai, Marie Pellat, Aitor Lewkowycz, Erica Moreira, Rewon Child, Oleksandr Polozov, Katherine Lee, Zongwei Zhou, Xuezhi Wang, Brennan Saeta, Mark Diaz, Orhan Firat, Michele Catasta, Jason Wei, Kathy Meier-Hellstern, Douglas Eck, Jeff Dean, Slav Petrov e Noah Fiedel. 2022. PaLM: Scaling Language Modeling with Pathways. *Preprint arXiv arXiv:2204.02311* (2022).
- [17] Jacob Cohen. 1960. Un coefficiente di concordanza per scale nominali. *Misurazione educativa e psicologica* 20, 1 (1960), 37–46.
- [18] Silviu Cucerzan. 2007. Disambiguazione su larga scala delle entità denominate basata sui dati di Wikipedia. In *EMNLP-CoNLL 2007, Atti della conferenza congiunta 2007 sui metodi empirici nell'elaborazione del linguaggio naturale e nell'apprendimento automatico delle lingue*, 28-30 giugno 2007, Praga, Repubblica Ceca. ACL, 708–716.
- [19] Silviu Cucerzan. 2012. Il sistema MSR per il collegamento delle entità. In *Conferenza sull'analisi del testo 2012*. NIST.
- [20] Sunhao Dai, Ninglu Shao, Haiyuan Zhao, Weijie Yu, Zihua Si, Chen Xu, Zhongxiang Sun, Xiao Zhang e Jun Xu. 2023. Alla scoperta delle capacità di ChatGPT nei sistemi di raccomandazione. In *Atti della 17a Conferenza ACM sui sistemi di raccomandazione, RecSys 2023, Singapore, Singapore, 18-22 settembre 2023*. ACM, 1126–1132.
- [21] Nicola De Cao, Gautier Izacard, Sebastian Riedel e Fabio Petroni. 2021. Recupero autoregressivo delle entità. In *9a Conferenza internazionale sull'apprendimento delle rappresentazioni, ICLR 2021, evento virtuale, Austria, 3-7 maggio 2021*.
- [22] Mostafa Dehghani, Sascha Rothe, Enrique Alfonseca e Pascal Fleury. 2017. Imparare ad ascoltare, copiare e generare per suggerimenti di query basati su sessioni. In *Atti della Conferenza ACM 2017 sulla gestione delle informazioni e delle conoscenze, CIKM 2017, Singapore, 6-10 novembre 2017*. ACM, 1747–1756.
- [23] Mostafa Dehghani, Sascha Rothe, Enrique Alfonseca e Pascal Fleury. 2017. Imparare ad ascoltare, copiare e generare suggerimenti di query basati su sessioni. In *Atti della conferenza ACM 2017 sulla gestione delle informazioni e delle conoscenze*, CIKM 2017, Singapore, 6-10 novembre 2017. ACM, 1747–1756.
- [24] Jacob Devlin, Ming-Wei Chang, Kenton Lee e Kristina Toutanova. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *NAACL*. Association for Computational Linguistics.
- [25] Heng Ding, Shuo Zhang, Dario Garigliotti e Krisztian Balog. 2018. Generazione di suggerimenti di query di alta qualità per la ricerca basata su attività. In *Advances in Information Retrieval - 40a Conferenza europea sulla ricerca IR, ECIR 2018, Grenoble, Francia, 26-29 marzo 2018, Atti (Lecture Notes in Computer Science, Vol. 10772)*. Springer, 625–631.
- [26] Wenqi Fan, Zihui Zhao, Jiatong Li, Yunqing Liu, Xiaowei Mei, Yiqi Wang, Jiliang Tang e Qing Li. 2023. Sistemi di raccomandazione nell'era dei modelli di apprendimento automatico linguistico su larga scala (LLM). *Preprint arXiv arXiv:2307.02046* (2023).
- [27] Luke Friedman, Sameer Ahuja, David Allen, Zhenning Tan, Hakim Sidahmed, Changbo Long, Jun Xie, Gabriel Schubiner, Ajay Patel, Harsh Lara, Brian Chu, Zexi Chen e Manoj Tiwari. 2023. Sfruttare i modelli linguistici di grandi dimensioni nei sistemi di raccomandazione conversazionali dell'. *Preprint arXiv arXiv:2305.07961* (2023).
- [28] Dario Garigliotti e Krisztian Balog. 2017. Generazione di suggerimenti di query a supporto della ricerca basata su attività. In *Atti della 40a Conferenza internazionale ACM SIGIR sulla ricerca e lo sviluppo nel recupero delle informazioni, Shinjuku, Tokyo, Giappone, 7-11 agosto 2017*. ACM, 1153–1156.
- [29] Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge e Yongfeng Zhang. 2022. Raccomandazione come elaborazione linguistica (RLP): un paradigma unificato di pre-addestramento, prompt personalizzato e previsione (P5). In *RecSys '22: Sedicesima conferenza ACM sui sistemi di raccomandazione basati sull', Seattle, WA, USA, 18-23 settembre 2022*. ACM, 299–315.
- [30] Zhankui He, Zhouhang Xie, Rahul Jha, Harald Steck, Dawen Liang, Yesu Feng, Bodhisattwa Prasad Majumder, Nathan Kallus e Julian J. McAuley. 2023. Grandi modelli linguistici come sistemi di raccomandazione conversazionali zero-shot. *Preprint arXiv arXiv:2308.10053* (2023).
- [31] Chao-Chun Hsu, Eric Lind, Luca Soldaini e Alessandro Moschitti. 2021. Generazione di risposte per sistemi di risposta alle domande basati sul recupero. In *Risultati dell'Associazione per la Linguistica Computazionale: ACL/IJCNLP 2021, evento online, 1-6 agosto 2021 (Risultati dell'ACL, Vol. ACL/IJCNLP 2021)*. Associazione per la Linguistica Computazionale, 4276–4282.
- [32] Jianchao Ji, Zelong Li, Shuyuan Xu, Wenyue Hua, Yingqiang Ge, Juntao Tan e Yongfeng Zhang. 2023. GenRec: modello linguistico di grandi dimensioni per la raccomandazione generativa di. *Preprint arXiv arXiv:2307.00457* (2023).
- [33] Di Jiang, Kenneth Wai-Ting Leung, Jan Vosecky e Wilfred Ng. 2014. Suggerimenti di ricerca personalizzati con consapevolezza della diversità. In *IEEE 30th International Conference on Data Engineering, Chicago, ICDE 2014, IL, USA, 31 marzo - 4 aprile 2014*. IEEE Computer Society, 400–411.
- [34] Jun-Yu Jiang e Wei Wang. 2018. RIN: Rete di inferenza di riformulazione per suggerimenti di query sensibili al contesto. In *Atti della 27a Conferenza internazionale ACM sulla gestione delle informazioni e della conoscenza, CIKM 2018, Torino, Italia, 22-26 ottobre 2018*. ACM, 197–206.
- [35] Minki Kang, Jinheon Baek e Sung Ju Hwang. 2022. KALA: Adattamento del modello linguistico aumentato basato sulla conoscenza Augmented Language Model Adaptation. In *Atti della Conferenza 2022 della Sezione Nordamericana dell'Associazione per la Linguistica Computazionale: Tecnologie del linguaggio umano, NAACL 2022, Seattle, WA, Stati Uniti, 10-15 luglio 2022*. 5144–5167.
- [36] Wang-Cheng Kang, Jianmo Ni, Nikhil Mehta, Maheswaran Sathiamoorthy, Lichan Hong, Ed H. Chi e Derek Zhiyuan Cheng. 2023. I modelli di linguaggio grande (LLM) comprendono le preferenze degli utenti? Valutazione dei modelli LLM sulla previsione delle valutazioni degli utenti. *Preprint arXiv arXiv:2305.06474* (2023).
- [37] Eugene Kharitonov, Craig Macdonald, Pavel Serdyukov e Iadh Ounis. 2013. Modelli In-tent per contestualizzare e diversificare i suggerimenti di ricerca. In *22nd ACM*

- International Conference on Information and Knowledge Management, CIKM '13, San Francisco, CA, USA, 27 ottobre - 1 novembre 2013. ACM, 2303-2308.*
- [38] Mojtaba Komeili, Kurt Shuster e Jason Weston. 2022. Generazione di dialoghi potenziata da Internet. In *Atti del 60° incontro annuale dell'Associazione per Computational Linguistics (Volume 1: Long Papers)*.
- [39] Andrew K. Lampinen, Ishita Dasgupta, Stephanie C. Y. Chan, Kory W. Mathewson, Mh Tessler, Antonia Creswell, James L. McClelland, Jane Wang e Felix Hill. 2022. I modelli linguistici possono imparare dalle spiegazioni contestualizzate? In *Risultati dell'Associazione per la Linguistica Computazionale: EMNLP 2022, Abu Dhabi, Emirati Arabi Uniti, 7-11 dicembre 2022. Associazione per la Linguistica Computazionale, 537-563*.
- [40] Angeliki Lazaridou, Elena Gribovskaya, Wojciech Stokowiec e Nikolai Grig-orev. 2022. Modelli linguistici potenziati da Internet attraverso prompting few-shot per la risposta a domande a dominio aperto. *Preprint arXiv arXiv:2203.05115* (2022).
- [41] Martin Josifoski Sebastian Riedel Luke Zettlemoyer Ledell Wu, Fabio Petroni. 2020. Collegamento di entità zero-shot con recupero denso di entità. In *EMNLP*.
- [42] Yibin Lei, Liang Ding, Yu Cao, Changfong Zan, Andrew Yates e Dacheng Tao. 2023. Recupero denso non supervisionato con pre-addestramento contrastivo sensibile alla rilevanza. In *Risultati dell'Associazione per la Linguistica Computazionale: ACL 2023*.
- [43] Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov e Luke Zettlemoyer. 2020. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. In *Atti del 58° incontro annuale dell'Associazione per Computational Linguistics, ACL 2020, online, 5-10 luglio 2020. Association for Computational Linguistics, 7871-7880*.
- [44] Cheng Li, Mingyang Zhang, Qiaozhu Mei, Yaqing Wang, Spurthi Amba Hombaiah, Yi Liang e Michael Bendersky. 2023. Insegnare agli LLM a personalizzare - Un approccio ispirato all'insegnamento della scrittura. *Preprint arXiv arXiv:2308.07968* (2023).
- [45] Lei Li, Yongfeng Zhang, Dugang Liu e Li Chen. 2023. Grandi modelli linguistici per la raccomandazione generativa: un'indagine e discussioni visionarie. *Preprint arXiv arXiv:2309.01157* (2023).
- [46] Junling Liu, Chao Liu, Renjie Lv, Kang Zhou e Yan Zhang. 2023. ChatGPT è un buon sistema di raccomandazione? Uno studio preliminare. *Preprint arXiv arXiv:2304.10149* (2023).
- [47] Yinhan Liu, Mylène Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer e Veselin Stoyanov. 2019. RoBERTa: un approccio di pre-addestramento BERT ottimizzato in modo robusto. *Preprint arXiv arXiv:1907.11692* (2019).
- [48] Hanjia Lyu, Song Jiang, Hanqing Zeng, Yinglong Xia e Jiebo Luo. 2023. LLM-Rec: raccomandazioni personalizzate tramite prompting di modelli linguistici di grandi dimensioni. *Preprint arXiv arXiv:2307.15780* (2023).
- [49] Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Hannaneh Hajishirzi e Daniel Khashabi. 2022. Quando non fidarsi dei modelli linguistici: indagine sull'efficacia e i limiti delle memorie parametriche e non parametriche. *Preprint arXiv arXiv:2212.10511* (2022).
- [50] Qiaozhu Mei, Dengyong Zhou e Kenneth Ward Church. 2008. Suggerimenti di query utilizzando il tempo di accesso. In *Atti della 17a Conferenza ACM sulla gestione delle informazioni e della conoscenza, CIKM 2008, Napa Valley, California, USA, ottobre 26-30 ottobre 2008. ACM, 469-478*.
- [51] Agnès Mustar, Sylvain Lamprier e Benjamin Piwowarski. 2020. Utilizzo di BERT e BART per i suggerimenti di query. In *Atti della prima conferenza congiunta delle comunità di recupero delle informazioni in Europa (CIRCLE 2020), Samatan, Gers, Francia, 6-9 luglio 2020 (Atti del workshop CEUR, vol. 2621). CEUR-WS.org*.
- [52] Agnès Mustar, Sylvain Lamprier e Benjamin Piwowarski. 2022. Sullo studio dei trasformatori di linguaggio per i suggerimenti di query. *ACM Trans. Inf. Syst.* 40, 1 (2022), 18:1-18:27.
- [53] OpenAI. 2023. Relazione tecnica GPT-4. *Preprint arXiv arXiv:2303.08774* (2023).
- [54] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang e Michael S. Bernstein. 2023. Generative Agents: Interactive Simulacra of Human Behavior. *Preprint arXiv:2304.03442* (2023).
- [55] Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick S. H. Lewis, Anton Bakhtin, Yuxiang Wu e Alexander H. Miller. 2019. Language Models as Knowledge Bases? In *Atti della Conferenza 2019 sui metodi empirici nell'elaborazione del linguaggio naturale e della 9a Conferenza internazionale congiunta sull'elaborazione del linguaggio naturale, EMNLP-IJCNLP 2019, Hong Kong, Cina, 3-7 novembre 2019. Associazione per la linguistica computazionale, 2463-2473*.
- [56] Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever, et al. 2018. Migliorare la comprensione del linguaggio attraverso il pre-addestramento generativo. (2018).
- [57] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li e Peter J. Liu. 2020. Esplorare i limiti del transfer learning con un trasformatore testo-testo unificato. *J. Mach. Learn. Res.* (2020).
- [58] Ori Ram, Yoav Levine, Itay Dalmedigos, Dor Muhlgay, Amnon Shashua, Kevin Leyton-Brown e Yoav Shoham. 2023. In-Context Retrieval-Augmented Language Models. *Preprint arXiv arXiv:2302.00083* (2023).
- [59] Adam Roberts, Colin Raffel e Noam Shazeer. 2020. Quanta conoscenza è possibile inserire nei parametri di un modello linguistico? In *Atti della Conferenza 2020 sui metodi empirici nell'elaborazione del linguaggio naturale, EMNLP* 2020, online, 16-20 novembre 2020. Associazione per la linguistica computazionale, 5418-5426.
- [60] Alireza Salemi, Sheshera Mysore, Michael Bendersky e Hamed Zamani. 2023. LaMP: Quando i modelli linguistici di grandi dimensioni incontrano la personalizzazione. *Preprint arXiv arXiv:2304.11406* (2023).
- [61] Pierangela Samarati e Latanya Sweeney. 1998. Proteggere la privacy quando si divulgano informazioni: k-anonimato e sua applicazione attraverso la generalizzazione e la soppressione. <https://api.semanticscholar.org/CorpusID:2181340>
- [62] Victor Sanh, Albert Webson, Colin Raffel, Stephen H. Bach, Lintang Sutawika, Zaid Alyafeai, Antoine Chaffin, Arnaud Stiegler, Arun Raja, Manan Dey, M Saiful Bari, Canwen Xu, Urmish Thakker, Shanya Sharma Sharma, Eliza Szczechla, Taewoon Kim, Gunjan Chhablani, Nihal V. Nayak, Debajyoti Datta, Jonathan Chang, Mike Tian-Jian Jiang, Han Wang, Matteo Manica, Sheng Shen, Zheng Xin Yong, Harshit Pandey, Rachel Bawden, Thomas Wang, Trishala Neeraj, Jos Rozen, Abheesht Sharma, Andrea Santilli, Thibault Févry, Jason Alan Fries, Ryan Teehan, Teven Le Scao, Stella Biderman, Leo Gao, Thomas Wolf e Alexander M. Rush. 2022. La formazione multitasking consente la generalizzazione delle attività zero-shot. In *The Tenth International Conference on Learning Representations, ICLR 2022, Evento virtuale*, 25-29 aprile 2022.
- [63] Weijia Shi, Sewon Min, Michihiro Yasunaga, Minjoon Seo, Rich James, Mike Lewis, Luke Zettlemoyer e Wen-tau Yih. 2023. REPLUG: modelli linguistici black-box basati su reti neurali generative () con recupero aumentato. *Preprint arXiv arXiv:2301.12652* (2023).
- [64] Kurt Shuster, Jing Xu, Mojtaba Komeili, Da Ju, Eric Michael Smith, Stephen Roller, Megan Ung, Moya Chen, Kushal Arora, Joshua Lane, Morteza Behrooz, William Ngan, Spencer Poff, Naman Goyal, Arthur Szlam, Y-Lan Boureau, Melanie Kam-badur e Jason Weston. 2022. BlenderBot 3: un agente conversazionale implementato che apprende continuamente a interagire in modo responsabile. *Preprint arXiv arXiv:2208.03188* (2022).
- [65] Alessandro Sordani, Yoshua Bengio, Hossein Vahabi, Christina Lioma, Jakob Grue Simonsen e Jian-Yun Nie. 2015. Un codificatore-decodificatore ricorrente gerarchico per suggerimenti di query generativi sensibili al contesto. In *Atti della 24a Conferenza internazionale ACM sulla gestione delle informazioni e della conoscenza, CIKM 2015, Melbourne, VIC, Australia, 19-23 ottobre 2015. ACM, 553-562*.
- [66] Alessandro Sordani, Yoshua Bengio, Hossein Vahabi, Christina Lioma, Jakob Grue Simonsen e Jian-Yun Nie. 2015. Un codificatore-decodificatore ricorrente gerarchico per suggerimenti generativi di query sensibili al contesto. In *Atti della 24a Conferenza internazionale ACM sulla gestione delle informazioni e della conoscenza, CIKM 2015, Melbourne, VIC, Australia, 19-23 ottobre 2015. ACM, 553-562*.
- [67] Muijeun Sung, Jinhuk Lee, Sean S. Yi, Minji Jeon, Sungdong Kim e Jaewoo Kang. 2021. I modelli linguistici possono essere basi di conoscenza biomedica? In *EMNLP. Associazione per la linguistica computazionale*.
- [68] Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam Shazeer, Apoorv Kul-shreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, YaGuang Li, Hongrae Lee, Huaixiu Steven Zheng, Amin Ghafouri, Marcelo Menegali, Yanping Huang, Maxim Krikun, Dmitry Lepikhin, James Qin, Dehao Chen, Yuanzhong Xu, Zhifeng Chen, Adam Roberts, Maarten Bosma, Yanqi Zhou, Chung-Ching Chang, Igor Krivokon, Will Rusch, Marc Pickett, Kathleen S. Meier-Hellstern, Meredith Ringel Morris, Tulsee Doshi, Renelito Delos Santos, Toju Duke, Johnny Soraker, Ben Zevenbergen, Vinodkumar Prabhakaran, Mark Diaz, Ben Hutchinson, Kristen Olson, Alejandra Molina, Erin Hoffman-John, Josh Lee, Lora Aroyo, Ravi Rajakumar, Alena Butryna, Matthew Lamm, Viktoriya Kuzmina, Joe Fenton, Aaron Cohen, Rachel Bernstein, Ray Kurzweil, Blaise Agüera y Arcas, Claire Cui, Marian Croak, Ed H. Chi e Quoc Le. 2022. LaMDA: Modelli di linguaggio generativo per applicazioni di dialogo. *Preprint arXiv arXiv:2201.08239* (2022).
- [69] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurélien Rodriguez, Armand Joulin, Edouard Grave e Guillaume Lam-ple. 2023. LLaMA: modelli linguistici di base aperti ed efficienti. *Preprint arXiv arXiv:2302.13971* (2023).
- [70] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajwal Bhargava, Shrutli Bhosale, Dan Bikel, Lukas Blecher, Cristian Canton-Ferrer, Moya Chen, Guillem Cucurull, David Esiobu, Jude Fernandes, Jeremy Fu, Wenyin Fu, Brian Fuller, Cynthia Gao, Vedanuj Goswami, Naman Goyal, Anthony Hartshorn, Saghar Hosseini, Rui Hou, Hakan Inan, Marcin Kardas, Viktor Kerkz, Madian Khabsa, Isabel Kloumann, Artem Korenev, Punit Singh Koura, Marie-Anne Lachaux, Thibaut Lavril, Jenya Lee, Diana Liskovich, Yinghai Lu, Yuning Mao, Xavier Martinet, Todor Mihaylov, Pushkar Mishra, Igor Molybog, Yixin Nie, Andrew Poulton, Jeremy Reizenstein, Rashi Rungta, Kalyan Saladi, Alan Schelten, Ruan Silva, Eric Michael Smith, Ranjan Subramanian, Xiaoqing Ellen Tan, Binh Tang, Ross Taylor, Adina Williams, Jian Xiang Kuan, Puxin Xu, Zheng Yan, Iliyan Zarov, Yuchen Zhang, Angela Fan, Melanie Kambadur, Sharan Narang, Aurélien Ro-driguez, Robert Stojnic, Sergey Edunov e Thomas Scialom. 2023. Llama 2: Open Foundation and Fine-Tuned Chat Models. *Preprint arXiv arXiv:2307.09288* (2023).
- [71] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser e Illia Polosukhin. 2017. L'attenzione è tutto ciò di cui hai bisogno. In *NeurIPS*.

- [72] Thanh Vu, Alistair Willis, Udo Kruschwitz e Dawei Song. 2017. Suggerimenti personalizzati per la ricerca nella rete intranet con profilazione temporale degli utenti. In *Atti della conferenza 2017 sull'interazione e il recupero delle informazioni umane, CHIIR 2017, Oslo, Norvegia, 7-11 marzo 2017*. ACM, 265–268.
- [73] Yancheng Wang, Ziyang Jiang, Zheng Chen, Fan Yang, Yingxue Zhou, Eunah Cho, Xing Fan, Xiaojang Huang, Yanbin Lu e Yingzhen Yang. 2023. RecMind: agente basato su un modello linguistico di grandi dimensioni per la raccomandazione. *Preprint arXiv arXiv:2308.14296* (2023).
- [74] Jason Wei, Maarten Bosma, Vincent Y. Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M. Dai e Quoc V. Le. 2022. I modelli linguistici ottimizzati sono sistemi di apprendimento zero-shot. In *The Tenth International Conference on Learning Representations, ICLR 2022, evento virtuale, 25-29 aprile 2022*.
- [75] Jerry W. Wei, Jason Wei, Yi Tay, Dustin Tran, Albert Webson, Yifeng Lu, Xinyun Chen, Hanxiao Liu, Da Huang, Denny Zhou e Tengyu Ma. 2023. I modelli linguistici più grandi apprendono in modo diverso nel contesto. *Preprint arXiv arXiv:2303.03846* (2023).
- [76] Jimmy Wu, Rika Antonova, Adam Kan, Marion Lepert, Andy Zeng, Shuran Song, Jeannette Bohg, Szymon Rusinkiewicz e Thomas A. Funkhouser. 2023. TidyBot: assistenza robotizzata personalizzata con modelli linguistici di grandi dimensioni. *Preprint arXiv arXiv:2305.05658* (2023).
- [77] Likang Wu, Zhi Zheng, Zhaopeng Qiu, Hao Wang, Hongchao Gu, Tingjia Shen, Chuan Qin, Chen Zhu, Hengshu Zhu, Qi Liu, Hui Xiong e Enhong Chen. 2023. Indagine sui modelli linguistici di grandi dimensioni per la raccomandazione. *Preprint arXiv arXiv:2305.19860* (2023).
- [78] Wenhao Yu, Dan Iter, Shuohang Wang, Yichong Xu, Mingxuan Ju, Soumya Sanyal, Chenguang Zhu, Michael Zeng e Meng Jiang. 2023. Generare anziché recuperare: I modelli linguistici di grandi dimensioni sono potenti generatori di contesto. In *The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Ruanda, 1-5 maggio 2023*.
- [79] Kai Zhang, Fubang Zhao, Yangyang Kang e Xiaozhong Liu. 2023. Personalizzazione LLM con memoria potenziata e coordinamento della memoria a breve e lungo termine. *Preprint arXiv arXiv:2309.11696* (2023).
- [80] Saizheng Zhang, Emily Dinan, Jack Urbanek, Arthur Szlam, Douwe Kiela e Jason Weston. 2018. Personalizzazione degli agenti di dialogo: ho un cane, anche tu hai animali domestici? In *Atti del 56° incontro annuale dell'Associazione per la linguistica computazionale (Volume 1: articoli lunghi)*.
- [81] Jianling Zhong, Weiwei Guo, Huiji Gao e Bo Long. 2020. Suggerimenti di ricerca personalizzati. In *Atti della 43a conferenza internazionale ACM SIGIR sulla ricerca e lo sviluppo nel campo del recupero delle informazioni, SIGIR 2020, evento virtuale, Cina, 25-30 luglio 2020*. ACM, 1645–1648.
- [82] Zile Zhou, Xiao Zhou, Mingzhe Li, Yang Song, Tao Zhang e Rui Yan. 2022. Suggerimenti di ricerca personalizzati con flusso dinamico di ricerca per il reclutamento online. In *Atti della 31a conferenza internazionale ACM sulla gestione delle informazioni e della conoscenza, Atlanta, GA, USA, 17-21 ottobre 2022*. ACM, 2773–2783.

A PROMPT

In questa sezione forniamo il prompt per il framework K-LaMP nella Tabella 8, che utilizziamo per ottenere risposte dagli LLM per suggerimenti di query contestuali personalizzati.

B ESEMPI DI SUGGERIMENTI DI RICERCA

Forniamo esempi basati su un confronto reale tra diversi approcci di suggerimento di query, inclusi modelli commerciali di suggerimento di query implementati in motori di ricerca web pubblici come Microsoft Bing e Google. Per questo confronto, utilizziamo l'esempio creato nella tabella 6, che racchiude una query dell'utente su "Tim Cook" che porta a una pagina web sulla "leadership di Tim Cook", nonché una serie di entità personali a cui l'utente è stato storicamente interessato (come i prodotti Apple). Esempi di suggerimenti di query da diversi approcci sono mostrati nella tabella 7. Questi dimostrano come K-LaMP contestualizzi meglio i suggerimenti sulla pagina corrente che l'utente sta consultando. Ad esempio, la query "Differenza tra l'approccio di Tim Cook e quello di Steve Jobs allo sviluppo dei prodotti Apple" è una richiesta di informazioni contrastive che sfrutta il contesto dell'utente, mentre "Stile di leadership di Tim Cook" (dal metodo di suggerimento di query non contestuale) non è particolarmente utile dato che questo è già l'argomento della pagina corrente. I suggerimenti di K-LaMP catturano anche meglio le conoscenze e gli interessi impliciti dell'utente, sulla base del comportamento di navigazione storico. Ad esempio, il suggerimento "L'impatto di Tim Cook sulla linea di prodotti Apple" è più in linea con gli interessi apparentemente tecnofili dell'utente rispetto al suggerimento incentrato sul gossip sulle celebrità "Tim Cook fidanzato" dei metodi di suggerimento delle query commerciali nei motori di ricerca web.

Tabella 6: Un esempio artificiale che mostra il tipo di dati forniti ai giudici umani.

Tipi	Testi
Query	Tim Cook
Sessione	Apple Tim Cook
Articolo	La leadership di Tim Cook: un nuovo profilo esamina come Tim Cook, CEO di Apple, con la sua leadership "cauta, collaborativa e tattica", abbia trasformato il gigante tecnologico di Cupertino nella più grande azienda al mondo. (. . .)
Entità di tendenza	"GPT-4", "OpenAI", "Google Bard", "Microsoft Copilot", "Elon Musk", . . .
Sintesi personale	L'utente è interessato ai prodotti e alla tecnologia Apple ("Macbook", "macOS" e "Apple TV"). Ha un forte interesse per il machine learning, con argomenti come "apprendimento supervisionato" e "ottimizzazione". Inoltre, ama l'animazione e mostra interesse per "Studio Ghibli", "Walt Disney" e "Pixar". Le sue preferenze si estendono anche all'home entertainment ("DVD" e "HDTV"). Infine, segue il baseball ("MLB" e "New York Yankees").
Entità personali	"Macbook", "macOS", "apprendimento automatico", "ottimizzazione", "apprendimento supervisionato", "Apple TV", "animazione", "Studio Ghibli", "DVD", "Walt Disney", "Pixar Animation Studios", "Apple Inc.", "Baseball", "HDTV", "Major League Baseball", "New York Yankees", ...

Tabella 7: Risultati dei suggerimenti di query di diversi approcci, inclusi metodi non contestuali e commerciali, basati sull'esempio di dati nella tabella 6.

Modelli	Risultati dei suggerimenti di query
Ricerca Microsoft Bing	"Tim Cook fidanzato", "Tim Cook ultime notizie"
Ricerca Google	"Citazioni di Tim Cook", "Tim Cook fidanzato"
Suggerimenti di ricerca senza contesto	"Stile di leadership di Tim Cook", "Patrimonio netto di Tim Cook"
K-LaMP (nostro)	"L'impatto di Tim Cook sulla linea di prodotti Apple", "Differenza tra l'approccio di Tim Cook e quello di Steve Jobs allo sviluppo dei prodotti Apple"

Tabella 8: Il prompt utilizzato nell'istanza completa di K-LaMP.

Tipi	Testi
Messaggio di sistema	Sei un assistente AI il cui obiettivo principale è suggerire una query di ricerca successiva, al fine di aiutare un utente a cercare e trovare informazioni sul motore di ricerca. Due query ed entità diverse sono separate dal token " ". Ad esempio, "Microsoft" e "Google" apparirebbero come "Microsoft" "Google". Suggerirai una query di ricerca che l'utente potrebbe cercare successivamente in base alla query corrente, alla sessione corrente, all'articolo corrente e alle entità personali. Le spiegazioni relative a query, sessione, articolo ed entità personali sono le seguenti: - La query è un insieme specifico di frasi che l'utente inserisce nel motore di ricerca per trovare le informazioni o le risorse relative a un particolare argomento, domanda o interesse. - La sessione si riferisce a una sequenza di query richieste dall'utente sul motore di ricerca, entro un certo periodo di tempo o in relazione al completamento di un'attività. - L'articolo si riferisce a una pagina web specifica che l'utente clicca e legge tra i diversi risultati di ricerca visualizzati dal motore di ricerca in risposta alla query richiesta. - L'entità personale si riferisce a un argomento, una parola chiave, una persona, un evento o qualsiasi soggetto che sia specificamente rilevante o interessante per il singolo utente in base ai suoi interessi personali.
Messaggio utente	Leggi la seguente query, sessione, articolo ed entità personali dell'utente come informazioni di contesto, che potrebbero essere utili e rilevanti per suggerire la query successiva. Query: {Query} Sessione: {Sessione} Titolo dell'articolo: {Articolo["Titolo"]} Testo dell'articolo: {Articolo["Testo"]} Entità personali: {Entità} Sulla base della query, della sessione, dell'articolo e delle entità personali sopra indicati, genera un suggerimento per la query successiva con la motivazione, nel formato Suggerimento di query: Motivazione: