

Report Dettagliato sul Framework K-LaMP: Modelli Linguistici di Grande Scala Aumentati dalla Conoscenza per il Suggerimento Contestuale Personalizzato di Query

Titolo, Autori e Riferimenti Accademici

Il documento analizzato introduce un'architettura innovativa nel campo dell'Information Retrieval e dell'Intelligenza Artificiale. Il titolo completo in traduzione italiana è: **Modelli Linguistici di Grande Scala Aumentati dalla Conoscenza (K-LaMP) per il Suggerimento Contestuale Personalizzato di Query**.

Questo lavoro è stato formalmente presentato e accettato per la pubblicazione a *The Web Conference (WWW) 2024*.¹ Il riferimento scientifico associato è l'identificatore arXiv:2311.06318 e il DOI accademico è 10.1145/3589334.3645404.¹

Abstract (Sintesi Tecnica)

Nonostante i Modelli Linguistici di Grande Scala (LLM) eccellano nella gestione di diversi compiti di linguaggio naturale, la loro personalizzazione per riflettere le esigenze individuali degli utenti rimane una sfida significativa. Il costo elevato del *re-training* o del *fine-tuning* rende gli LLM essenzialmente statici e difficili da adattare su scala utente.³ Tuttavia, in applicazioni critiche come la ricerca web, è fondamentale che gli output siano adattati alle preferenze, agli obiettivi e, soprattutto, alla **conoscenza** specifica dell'utente per migliorare l'esperienza complessiva.³

Per colmare questa lacuna, il lavoro propone K-LaMP (Knowledge-augmented large Language Models for Personalization), un approccio generale e innovativo che aumenta l'LLM con il contesto rilevante ricavato dalle storie di interazione degli utenti con un motore di ricerca.³ L'architettura principale di K-LaMP si basa sulla costruzione di un **knowledge store centrato sull'entità** (*entity-centric knowledge store*) dedicato a ciascun utente, derivato dalle sue attività passate di ricerca e navigazione.³ Un elemento distintivo è la natura **light-weight** (leggera) di questo *knowledge store*, che produce solamente proiezioni aggregate degli interessi e della conoscenza dell'utente su grafi di conoscenza pubblici. Questo design sfrutta l'infrastruttura di *search log* esistente, mitigando efficacemente le preoccupazioni di privacy, conformità normativa e scalabilità che affliggono i metodi basati sulla costruzione di profili utente profondi.³

L'efficacia di K-LaMP è stata validata attraverso il compito del suggerimento contestuale di query, un'attività che impone al sistema non solo di considerare il contesto di ricerca immediato, ma anche la conoscenza storica e gli interessi dell'utente.³ I risultati sperimentali, basati su una rigorosa valutazione umana, hanno dimostrato che l'approccio K-LaMP supera significativamente diverse *baselines* alimentate da LLM, generando suggerimenti che sono **contestualmente più rilevanti, personalizzati e utili**.¹

Sezione 1: INTRODUZIONE

1.1. Il Paradosso degli LLM: Conoscenza Generale vs. Rilevanza Individuale

I Modelli Linguistici di Grande Scala, come GPT-4, sono riconosciuti per la loro capacità di internalizzare una vasta conoscenza generale grazie all'addestramento su enormi corpora testuali. Questa competenza permette loro di generare risposte plausibili, coerenti e utili in risposta a input generici.⁴ Nonostante questi successi, la sfida della personalizzazione degli output rimane, poiché l'adattamento delle risposte a preferenze, bisogni e, in particolare, alla **conoscenza** individuale degli utenti è essenziale per applicazioni cruciali come il suggerimento di query o i sistemi di raccomandazione.⁴

Il principale ostacolo operativo e finanziario è l'onere computazionale: il *re-training* o il *fine-tuning* degli LLM per ogni singolo utente risultano proibitivamente costosi su scala

industriale.⁴

1.2. Analisi Critica delle Tecniche di Personalizzazione Esistenti

I primi tentativi di personalizzazione degli LLM si sono concentrati sull'aumento dell'input dell'utente attraverso l'**In-Context Learning (ICL)**, anteponendo sequenze della loro storia di interazione nel *prompt*.⁴ Tuttavia, questa metodologia incontra due limitazioni fondamentali. In primo luogo, l'elevato volume di informazioni storiche degli utenti spesso eccede la capacità della finestra di *prompt* dell'LLM.⁴ In secondo luogo, non tutta la cronologia passata è pertinente al contesto della query corrente.⁶

Per mitigare i vincoli di lunghezza, i lavori più recenti hanno introdotto la **Retrieval-Augmented Personalization (RAP)**, recuperando solo una frazione della cronologia più rilevante da una memoria completa.⁴ Sebbene efficace in compiti semplici, come la raccomandazione di prodotti, questo approccio si rivela insufficiente per scenari di personalizzazione più complessi dove è cruciale una comprensione profonda della **conoscenza personale** e della competenza dell'utente in un dato dominio.⁴ Un'alternativa, la personalizzazione basata su profili utente dettagliati, sebbene promettente per catturare la conoscenza, impone compromessi in termini di privacy e scalabilità, richiedendo un *modeling online* complesso che va oltre le capacità standard dell'infrastruttura di *logging* esistente.⁴

1.3. Il Framework K-LaMP: Una Soluzione Centrata sull'Entità

Per superare i limiti di scalabilità, costo, e profondità cognitiva dei metodi preesistenti, è stato introdotto il framework K-LaMP. Questo approccio si basa su un **layer di personalizzazione leggero e centrato sull'entità** che aumenta gli LLM con entità contestuali.⁴

La fonte di questa conoscenza è un *knowledge store* personale derivato direttamente dai **log di ricerca esistenti**.⁴ Questo *store* si costruisce progressivamente aggregando le entità menzionate nelle query emesse dall'utente o nelle pagine web da lui navigate. È arricchito da "viste" differenziate che categorizzano le entità in base a quanto l'utente possa esserne **familiare, non familiare, o se siano recentemente lapsate** (dimenticate).⁴

1.4. Vantaggi Unici della Strategia K-LaMP

La strategia di personalizzazione centrata sull'entità offre numerosi vantaggi ingegneristici e operativi. In primo luogo, il recupero contestualmente rilevante da questo *store* incoraggia gli LLM a generare output che sono profondamente radicati nella conoscenza e negli interessi dell'utente, superando l'efficacia dei log di query memorizzati in sequenza lineare.⁴

In secondo luogo, la dipendenza dall'infrastruttura di *logging* già esistente rende K-LaMP più gestibile in termini di privacy, flessibilità e scalabilità rispetto ai modelli basati su profili complessi. Ciò si traduce in una riduzione dell'overhead legato alla raccolta dati, al *modeling* e all'aggiornamento.⁴

Infine, il metodo di aumento della conoscenza è estremamente **costo-efficiente**. L'iniezione di conoscenza sfrutta le entità come "atomi" di contesto, risultando in aggiunte **minimali e succinte** al prompt. Questo massimizza l'efficacia informativa pur ottimizzando l'uso dei token, un fattore critico per l'efficienza dei costi operativi degli LLM, a differenza di altri approcci che contestualizzano mediante testo grezzo.⁴

1.5. L'Applicazione al Suggerimento Contestuale Personalizzato di Query

Sebbene K-LaMP sia applicabile a una vasta gamma di problemi di personalizzazione, esso trova una rilevanza particolare nei task che richiedono la modellazione esplicita della **conoscenza** dell'utente, oltre ai suoi semplici interessi.⁴ Il compito scelto per la validazione è il suggerimento contestuale di query.

In questo scenario, il sistema deve raccomandare query non solo sulla base della cronologia utente, ma anche condizionandole sul **testo completo della pagina web che l'utente sta attualmente visualizzando**.⁴ Questo è fondamentale perché conoscere il dominio di competenza e la padronanza di un utente rispetto a un argomento specifico può alterare radicalmente i suggerimenti. Ad esempio, se un utente con una profonda conoscenza della medicina sta leggendo un articolo su un farmaco, il sistema K-LaMP suggerirà una query tecnica e specifica, mentre un modello ingenuo fornirebbe una query generica o definitoria. Questa necessità di modellare il divario di conoscenza differenzia il task di K-LaMP dal tradizionale *context-aware query suggestion*, che storicamente si basava solo su associazioni superficiali (come i titoli delle pagine).⁴

Sezione 2: CONTESTO E LAVORI CORRELATI

2.1. Acquisizione e Limiti della Conoscenza negli LLM

Gli LLM, grazie alle architetture Transformer e al vasto numero di parametri, hanno dimostrato capacità notevoli di ritenzione della conoscenza e generalizzazione su domini diversi.⁴ L'adattamento generico dei modelli è spesso realizzato tramite *prompt engineering*, dove la conoscenza fattuale esterna viene utilizzata per aumentare la precisione delle risposte.⁴ Tuttavia, l'obiettivo del *presente* lavoro non è aumentare la conoscenza fattuale universale, ma piuttosto indirizzare le lacune nella personalizzazione degli output per l'utente individuale.

2.2. L'Evoluzione della Personalizzazione degli LLM

La personalizzazione degli LLM, applicata a diversi settori come raccomandazioni, assistenza alla scrittura e generazione di dialogo, è evoluta. Inizialmente, si procedeva tramite l'incorporazione lineare della sequenza storica di interazione (es. log di acquisto).⁴ Come già sottolineato, la limitazione principale era data dalla lunghezza eccessiva delle sequenze, che superava la capacità delle finestre di *prompt*.⁶ Successivamente, i metodi basati su RAG hanno proposto il recupero di contenuti pertinenti da una memoria esterna.⁶

Tuttavia, questi approcci intermedi rimangono insufficienti per modellare la **competenza profonda** dell'utente.⁴ La personalizzazione basata su log lineari o recupero superficiale non riesce a distinguere tra un interesse passeggero e una conoscenza consolidata. È proprio su questo punto che il framework K-LaMP introduce una distinzione critica: l'uso dello *store* centrato sull'entità permette di astrarre la cronologia in un profilo di competenza leggero ma significativo.

2.3. Differenziazione dal Query Suggestion Tradizionale

I lavori precedenti sul suggerimento di query si basavano su modelli statistici (come Markov o LDA) o su architetture neurali, concentrandosi sul modellare la sequenza di query precedenti.⁴ I sistemi più vicini, definiti *context-aware* nella letteratura precedente, sfruttavano al massimo associazioni superficiali con pagine cliccate (ad esempio, analizzando solo i titoli).⁴

Il task affrontato da K-LaMP, il **suggerimento contestuale personalizzato di query**, è nuovo e pratico in quanto richiede esplicitamente la contestualizzazione del **testo completo** della pagina web visualizzata e l'integrazione della conoscenza esplicita dell'utente.⁴ Questa elevata richiesta di ragionamento contestuale è ciò che rende gli LLM, opportunamente aumentati, gli strumenti più adatti per la risoluzione del problema.

Sezione 3: K-LaMP: LLM AUMENTATI DALLA CONOSCENZA PER IL SUGGERIMENTO PERSONALIZZATO DI QUERY

3.1. Introduzione al Framework Architeturale

L'approccio K-LaMP è fondamentalmente una metodologia di RAG personalizzata, ma si distingue per la natura atomica e strutturata dell'informazione recuperata. Il sistema è progettato per integrare il contesto di interazione storica con la finestra di contesto attuale dell'LLM.

Come illustrato concettualmente nella Figura 2 (Panoramica di K-LaMP)⁴:

1. Il sistema riceve in input (A) i log di ricerca passati dell'utente e (B) il contesto di ricerca attuale, che include la query corrente e la pagina web visualizzata.
2. I log di ricerca vengono memorizzati in uno **stream di memoria** unitamente ai relativi *timestamp* (C).
3. Le entità pertinenti vengono estratte da questo stream e aggregate per costruire lo **store di conoscenza basato sull'entità** (D).
4. Le entità più rilevanti per il contesto attuale vengono recuperate da (D) e utilizzate per aumentare il prompt dell'LLM (E), consentendo a K-LaMP di generare suggerimenti che riflettono sia l'interesse contestuale che la conoscenza pregressa dell'utente.⁴

3.2. Il Knowledge Store Personale Centrato sull'Entità

Il cuore di K-LaMP risiede nel suo *knowledge store* personale. Questo deposito aggrega le entità associate alle interazioni passate dell'utente, rappresentando un profilo di competenza dinamico. La designazione di *light-weight* sottolinea un aspetto cruciale di ingegneria dei sistemi: si evitano i costi e i rischi associati alla modellazione psicologica profonda, preferendo invece proiezioni aggregate su grafi di conoscenza esterni, riducendo drasticamente l'overhead di *modeling* e di aggiornamento del profilo utente.⁴

Per ottenere una personalizzazione cognitiva avanzata, lo *store* non è gestito come un blocco unico, ma è segmentato in **viste differenziate della conoscenza**⁴:

1. **Entità Familiari:** Entità che l'utente ha incontrato e interagito con frequenza o molto recentemente, indicando competenza o interesse consolidato.
2. **Entità Non Familiari:** Entità che sono rilevanti per il dominio di interesse dell'utente ma che non sono state ancora incontrate o consumate, cruciali per suggerimenti di scoperta e ampliamento della conoscenza.⁴
3. **Entità Lapsate:** Entità che sono decadute dalla memoria recente, permettendo al sistema di riattivare vecchi interessi o conoscenze.

Questa modellazione cognitiva permette all'LLM di personalizzare l'output non solo basandosi su *cosa* l'utente cerca, ma anche su *quanto* ne sa, facilitando suggerimenti mirati che colmano il divario di conoscenza (Entità Non Familiari) o che offrono approfondimenti specialistici (Entità Familiari).⁴

3.3. Dettagli sul Processo di Augmentazione della Query

Il meccanismo attraverso il quale K-LaMP inietta la conoscenza nello strato di ragionamento dell'LLM è l'**augmentazione atomica**. La conoscenza recuperata viene aggiunta al *prompt* del modello utilizzando le entità come *atomi di contesto* succinti.⁴

Questa scelta è un elemento determinante per l'**efficienza computazionale** del framework. L'uso di aggiunte minimali e concise al *prompt* è ottimale per l'uso della finestra di contesto dell'LLM, garantendo che il rapporto tra informazione critica e token utilizzato sia massimizzato.⁴

La Figura 1, che illustra concettualmente il K-LaMP ⁴, evidenzia il beneficio di questa augmentazione:

- In uno scenario dove un utente (B) possiede conoscenza specifica (es. in medicina) derivata dalla sua attività passata, un sistema convenzionale (C) basato su LLM ingenuo genererebbe un suggerimento generico e irrilevante rispetto a quella competenza.
- Al contrario, K-LaMP (D) sfrutta la conoscenza (B) per suggerire una query altamente pertinente e specifica al livello di expertise dell'utente, dimostrando il *grounding* profondo garantito dall'approccio centrato sull'entità.⁴

Tabella 3.3.1 illustra sinteticamente i ruoli dei componenti K-LaMP:

Table 3.3.1: Ruoli e Benefici del Framework K-LaMP

Componente K-LaMP	Funzione Tecnica	Vantaggio Strategico (Privacy/Efficienza)
Large Language Model (LLM)	Generazione di output, ragionamento. ⁴	Sfrutta la vasta conoscenza pre-allenata.
Entity-centric Knowledge Store	Aggregazione di entità per costruire un profilo di competenza. ⁴	Leggero, scalabile, riduce l'overhead di <i>modeling</i> e preserva la privacy. ⁴
Viste della Conoscenza	Distinzione tra entità Familiari, Non Familiari, Lapsate. ⁴	Personalizzazione basata sulla competenza e non solo sull'interesse. ⁴
Augmentazione tramite Entità	Iniezione atomica e succinta di conoscenza nel prompt. ⁴	Costo-efficiente e ottimizza l'uso della finestra di contesto. ⁴

Sezione 4: CONFIGURAZIONE SPERIMENTALE E RISULTATI SULLA VALIDAZIONE UMANA

4.1. Setup Sperimentale e Dataset

La validazione dell'efficacia di K-LaMP è stata condotta sul task di suggerimento contestuale di query.⁴ Per garantire l'aderenza a un contesto reale, sono stati utilizzati log di ricerca effettivi provenienti dal motore di ricerca Bing, i quali hanno costituito anche la base per la costruzione dello *store* di conoscenza centrato sull'entità.⁴

4.2. Metodologia di Valutazione (Enfasi sulla Valutazione Umana)

Data la natura altamente personalizzata e soggettiva della *Usefulness* (Utilità) e della *Relatedness* (Rilevanza) in questo task, le metriche automatiche standard si sono rivelate insufficienti. Di conseguenza, il framework è stato validato tramite una rigorosa **valutazione umana** su una batteria di test.¹

Gli annotatori sono stati incaricati di valutare i risultati su 313 contesti di ricerca.⁴ È stato essenziale fornire loro un contesto informativo il più completo possibile per comprendere sia la situazione di ricerca attuale dell'utente sia i suoi interessi e la sua conoscenza storica (come dettagliato nell'esempio fornito nella Tabella 6, utilizzato come riferimento per gli annotatori).⁴

Le metriche di valutazione umana utilizzate sono state:

1. **Validity (Validità):** Misura la coerenza e la plausibilità grammaticale e tematica della query suggerita.⁴
2. **Relatedness (Rilevanza):** Misura la pertinenza contestuale, verificando il collegamento tra la query suggerita e sia la pagina web visualizzata che la query precedente.⁴
3. **Usefulness (Utilità):** Misura l'effettivo valore e vantaggio che il suggerimento offre all'utente specifico, tenendo conto del suo livello di conoscenza.¹

4.3. Risultati Sperimentali Principali

I risultati aggregati, in linea con la Tabella 1 del *paper*⁴, dimostrano che K-LaMP ha sovraperformato sostanzialmente diversi *baselines* alimentati da LLM.¹ In particolare, K-LaMP è risultato superiore nella generazione di raccomandazioni che non solo sono ben correlate al contesto, ma sono anche significativamente **più utili** all'utente individuale, mantenendo al

contempo un'alta qualità generale del suggerimento.⁴

Table 4.3.1: Risultati Principali sul Suggerimento Contestuale di Query (Sintesi)

Metodo	Metrica A: Relatedness (Rilevanza)	Metrica B: Usefulness (Utilità)
Baseline LLM (Generico)	Bassa	Bassa
Baseline LLM (Retrieval Log)	Media	Media
K-LaMP (Proposto)	Migliore in Assoluto	Migliore in Assoluto

4.4. Analisi Delle Varianti di K-LaMP

Per comprendere l'impatto delle diverse componenti di conoscenza, è stata condotta un'analisi approfondita sulle varianti del framework (Figura 3).⁴ Sono stati confrontati i risultati ottenuti utilizzando tutte le entità, solo le entità familiari o solo le entità non familiari.⁴

Questa analisi ha stabilito che la differenziazione delle entità ha un impatto causale e misurabile sulle metriche. Ad esempio, la capacità di K-LaMP di sfruttare le entità **non familiari** (ovvero quelle che suggeriscono una potenziale area di espansione della conoscenza per l'utente) contribuisce in modo significativo all'aumento del punteggio di *Usefulness*. Questo convalida l'ipotesi che un modello personalizzato debba non solo seguire gli interessi pregressi, ma anche identificare e indirizzare il divario di conoscenza dell'utente per fornire suggerimenti realmente vantaggiosi.

4.5. Prestazioni a Lungo Termine

Le analisi conclusive hanno dimostrato che K-LaMP non solo è efficace nell'immediato, ma mostra anche una notevole capacità di recuperare conoscenza contestualmente rilevante.⁴ Un risultato fondamentale è che il framework continua a migliorare le sue prestazioni man mano che vengono elaborati e archiviati log di interazione utente più lunghi.⁴ Ciò evidenzia la robustezza e la natura dinamica dello *knowledge store*, che è in grado di costruire un profilo di

competenza duraturo e in evoluzione, una caratteristica che i *baselines* concorrenti non sono riusciti a replicare.⁴

Sezione 5: DISCUSSIONE E CONTRIBUTO SCIENTIFICO

5.1. Sintesi dei Contributi Principali

Il lavoro fornisce contributi significativi sia alla modellazione degli LLM che ai sistemi di Information Retrieval (IR).⁵ K-LaMP rappresenta un nuovo e generale approccio per la personalizzazione degli LLM, che risolve le inefficienze legate ai costi e alla scalabilità dei metodi che richiedono *fine-tuning* o ampie finestre di *prompt*.³

Il successo della metodologia *entity-centric* nell'augmentazione della conoscenza costituisce un nuovo paradigma, garantendo un *grounding* più profondo degli output rispetto alla semplice iniezione di log di query lineari.⁴ Inoltre, la metodologia di valutazione adottata è stata elogiata dalla comunità scientifica per la sua rigosità, che include la costruzione di nuovi *dataset* e l'uso di metriche basate su giudizi umani, fattori che migliorano significativamente la valutazione in questo campo.⁵

5.2. Implicazioni per i Sistemi di Information Retrieval (IR)

L'efficacia di K-LaMP sposta il focus operativo degli LLM nei sistemi IR dalla mera corrispondenza testuale a una vera e propria **guida cognitiva**. Il sistema, modellando la conoscenza e la competenza dell'utente, è in grado di anticipare non solo ciò che l'utente *vuole* cercare, ma anche ciò di cui *ha bisogno* per progredire nel suo percorso di conoscenza.⁴ Dal punto di vista del design industriale, l'utilizzo di entità come *atomi di contesto* garantisce che K-LaMP sia ottimizzato per l'implementazione su larga scala, riducendo i costi operativi e massimizzando l'efficienza.⁴

5.3. Prospettive per il Lavoro Futuro

Nonostante i risultati positivi, la ricerca individua aree per l'espansione futura. Un punto sollevato dai revisori è la necessità di un confronto più esteso tra K-LaMP e i lavori esistenti di *query suggestion* non basati su LLM. Tale comparazione sarebbe fondamentale per quantificare l'importanza assoluta e separata dell'introduzione del "contesto" e della potenza di inferenza degli LLM in questo specifico task.⁵

Inoltre, il lavoro si inserisce in un trend emergente che suggerisce di ripensare l'assessment dell'adattabilità degli agenti personalizzati. Le future valutazioni dovrebbero evolvere da prove statiche a simulazioni longitudinali *task-grounded* che riflettano come la conoscenza e gli obiettivi degli utenti evolvono attraverso sessioni multiple.⁷

Appendice A: Dettagli sull'Implementazione e Baselines (Ricostruzione)

Gli Appendici (A e B), sebbene non disponibili nel testo completo fornito, sono essenziali per la riproducibilità scientifica.⁸ L'Appendice A conterrebbe i dettagli metodologici completi sull'implementazione del framework K-LaMP e la configurazione dei *baselines* utilizzati per il confronto.

Ciò include le specifiche dettagliate dei modelli LLM non personalizzati, dei modelli aumentati tramite semplice iniezione lineare dei log di ricerca, e del *baseline* "contextual query suggestion w/ Ks" che utilizza un *knowledge store* generico ma non la strategia *entity-centric* di K-LaMP. Inoltre, l'Appendice A fornirebbe i dettagli precisi del prompt utilizzato nell'istanziamento dei *baselines* (come descritto in riferimento alla Tabella 11).⁴

Appendice B: Dettagli su Raccolta Dati e Istruzioni per l'Annotazione Umana (Ricostruzione)

L'Appendice B includerebbe informazioni dettagliate sui processi di raccolta, anonimizzazione e pre-elaborazione dei log di ricerca da Bing utilizzati per il *dataset*.⁴ Fondamentale per la validazione, questa sezione descriverebbe in dettaglio le istruzioni fornite agli annotatori umani.

In particolare, verrebbe illustrato come gli annotatori sono stati guidati nella valutazione delle metriche (Validità, Rilevanza, Utilità), includendo esempi di contesto fornito (come l'esempio della Tabella 6).⁴ Tali istruzioni sono cruciali per garantire che gli annotatori potessero valutare con precisione la pertinenza di un suggerimento in relazione allo stato cognitivo ricostruito dell'utente, confermando la validità della metodologia di valutazione umana.⁴

Bibliografia

1. [2311.06318] Knowledge-Augmented Large Language Models for Personalized Contextual Query Suggestion - arXiv, accesso eseguito il giorno ottobre 9, 2025, <https://arxiv.org/abs/2311.06318>
2. Navigating the Unknown: A Chat-Based Collaborative Interface for, accesso eseguito il giorno ottobre 9, 2025, <https://www.emergentmind.com/papers/2410.24032>
3. Knowledge-Augmented Large Language Models for Personalized Contextual Query Suggestion - Bohrium, accesso eseguito il giorno ottobre 9, 2025, <https://www.bohrium.com/paper-details/knowledge-augmented-large-language-models-for-personalized-contextual-query-suggestion/931260827263041862-108611>
4. Knowledge-Augmented Large Language Models for Personalized Contextual Query Suggestion - arXiv, accesso eseguito il giorno ottobre 9, 2025, <https://arxiv.org/pdf/2311.06318>
5. Knowledge-Augmented Large Language Models for Personalized Contextual Query Suggestion | OpenReview, accesso eseguito il giorno ottobre 9, 2025, [https://openreview.net/forum?id=c2hFcVRRCl&referrer=%5Bthe%20profile%20of%20Sujay%20Kumar%20Jauhar%5D\(%2Fprofile%3Fid%3D~Sujay_Kumar_Jauhar2\)](https://openreview.net/forum?id=c2hFcVRRCl&referrer=%5Bthe%20profile%20of%20Sujay%20Kumar%20Jauhar%5D(%2Fprofile%3Fid%3D~Sujay_Kumar_Jauhar2))
6. Knowledge-Augmented Large Language Models for Personalized Contextual Query Suggestion - OpenReview, accesso eseguito il giorno ottobre 9, 2025, <https://openreview.net/pdf?id=c2hFcVRRCl>
7. (PDF) Beyond Static Evaluation: Rethinking the Assessment of Personalized Agent Adaptability in Information Retrieval - ResearchGate, accesso eseguito il giorno ottobre 9, 2025, https://www.researchgate.net/publication/396250970_Beyond_Static_Evaluation_Rethinking_the_Assessment_of_Personalized_Agent_Adaptability_in_Information_Retrieval
8. Tables, Appendices, Footnotes and Endnotes - Purdue OWL, accesso eseguito il giorno ottobre 9, 2025, https://owl.purdue.edu/owl/subject_specific_writing/writing_in_the_social_sciences/writing_in_psychology_experimental_report_writing/tables_appendices_footnotes_and_endnotes.html